SVEUČILIŠTE U ZAGREBU
FAKULTET STROJARSTVA I BRODOGRADNJE

OPTIMIZACIJSKE METODE U RAZVOJU I UPRAVLJANJU SUSTAVA

Optimizacijske metode u razvoju i upravljanju sustava

Profesor:

Prof. dr. sc. Andrej Jokić

Student:

Krešimir Hartl

Zagreb, 2026.

SADRŽAJ

1 Uvod **1**

1.1 Taksonomija konveksnih optimizacijskih problema 1

1.2 Struktura seminarskog rada 1

2 Kvadratno programiranje, KKT uvjeti, dualnost i analiza osjetljivosti **2**

2.1 Opis problema i provjera konveksnosti 2

2.1.1 Matrični kanonski zapis i dokaz stroge konveksnosti 3

2.1.2 Konveksnost dopustivog skupa i globalna optimalnost 4

2.2 Lagrangeova funkcija i KKT uvjeti optimalnosti 4

2.3 Analitičko rješavanje KKT sustava (4 kombinacije aktivnih skupova) 5

2.3.1 Slučaj 1: Oba ograničenja neaktivna ($\mu_1 = 0, \mu_2 = 0$) 5

2.3.2 Slučaj 2: Samo prvo ograničenje aktivno ($\mu_1 > 0, \mu_2 = 0$) 6

2.3.3 Slučaj 3: Samo drugo ograničenje aktivno ($\mu_1 = 0, \mu_2 > 0$) 7

2.3.4 Slučaj 4: Oba ograničenja aktivna ($\mu_1 > 0, \mu_2 > 0$) 7

2.4 Geometrijska interpretacija i ravnoteža gradijenata 8

2.5 Numerička verifikacija u programskim paketima 9

2.6 Lagrangeova dualnost i dokaz jake dualnosti 9

2.6.1 Provjera Slaterovog uvjeta i jaka dualnost 10

2.7 Analiza osjetljivosti i perturbacija ograničenja 11

2.7.1 Inženjerska i ekonomska interpretacija (cijene u sjeni) 11

3 Robusno kvadratno programiranje pod intervalnom nesigurnošću **12**

3.1 Koncept robusne optimizacije i definicija skupa nesigurnosti 12

3.2 Egzaktna derivacija deterministčkog robusnog ekvivalenta 13

3.3 Analitičko rješenje robusnog QP-a 14

3.4 Monte Carlo analiza dopustivosti i vizualizacija 15

3.5 Cijena robusnosti (*Price of Robustness*) 17

4 Optimizacijska nivelacija uzdužnog profila ceste primjenom linearnog programiranja **18**

4.1 Kontinuirana varijacijska formulacija problema 18

4.2 Diskretizacija konačnim razlikama 18

4.2.1 Aproksimacija prve i druge derivacije 19

4.3 Transformacija u standardni oblik linearnog programa (LP) 19

4.3.1 Struktura matrice nejednakosti $A_{\text{ineq}}\theta \leq b_{\text{ineq}}$ 20

4.3.2 Struktura matričnih jednakosti $A_{\text{eq}}\theta = b_{\text{eq}}$ 21

4.4 Numerički rezultati za četiri ispitna slučaja 21

4.5 Analiza utjecaja gustoće diskretizacije i parametara ograničenja 22

5 Robusna stabilizacija sklopnog sustava primjenom linearnih matričnih nejednakosti (LMI) 24

5.1 Matematički model sustava i analiza pojedinih modova 24

5.1.1 Spektralna analiza i Hurwitzovo svojstvo modova 25

5.2 Mehanizam destabilizacije i analiza monodromijske matrice 25

5.3 Zajednička funkcija Ljapunova (CQLF) i LMI formulacija 27

5.4 Kongruentna transformacija i supstitucija varijabli 27

5.5 Numerička sinteza regulatora u SDP okruženju 28

5.5.1 Provjera svojstvenih vrijednosti zatvorenog kruga 28

5.6 Simulacija zatvorenog kruga i dokaz eksponencijalne stabilnosti 29

6 Zaključak i sinteza rezultata 30

6.1 Sinteza rezultata po optimizacijskim zadacima 30

6.2 Komparativni osvrt i smjernice za inženjersku praksu 31

POPIS SLIKA

2.1 Geometrijski prikaz dopustivog skupa $\mathcal{F}$, nivo-krivulja funkcije cilja $f(x)$ i vektora gradijenata u KKT točki x^*. 8
2.2 Nivo-krivulje konkavne Lagrangeove dualne funkcije $g(\mu_1, \mu_2)$ i optimalna dualna točka $\mu^* = (12.242, 0.000)$. 10
2.3 Funkcija optimalne vrijednosti $p^*(b_1 + \Delta b_1)$ u usporedbi s linearnom aproksimacijom nagiba $-\mu_1^*$. 11
3.1 Robusni dopustivi skup, nominalne granice i Monte Carlo ovojnica dobivena iz 100 slučajnih realizacija parametara nesigurnosti. 16
3.2 Nivo-krivulje funkcije cilja, pomak točke optimuma i geometrijska vizualizacija cijene robusnosti Δf^*. 17
4.1 Optimalni uzdužni profil ceste $y(x)$ za Slučaj A ($b_1 = 0.5, b_2 = 0.5$) s označenim zonama iskopa i nasipa. 22
4.2 Optimalni uzdužni profil ceste $y(x)$ za Slučaj B ($b_1 = 0.5, b_2 = 0.2$) uz strože ograničenje zakrivljenosti. 22
4.3 Provjera ograničenja prvog reda: profil nagiba ceste $y'(x)$ duž trase za Slučaje A i B. 23
4.4 Provjera ograničenja drugog reda: profil zakrivljenosti $y''(x)$ i zasićenje na granicama $\pm b_2$. 24
5.1 Simulacija otvorenog kruga: vremenski odziv stanja $x_1(t), x_2(t)$ i fazni portret koji prikazuje divergenciju (ekspandirajuću spiralu) uslijed prespajanja. 26
5.2 Simulacija zatvorenog kruga: stabilizirani vremenski odziv stanja i fazni portret s eliptičnim nivo-plohama funkcije Ljapunova $x^T P x = c$. 29
5.3 Vremenska disipacija energije zajedničke funkcije Ljapunova $V(x(t))$ u logaritamskom mjerilu uz usporedbu s teorijskom eksponencijalnom ovojnicom. 30

POPIS TABLICA

2.1 Usporedba analitičkih i numeričkih rezultata za Zadatak 1. 9
3.1 Monte Carlo provjera dopustivosti nominalnog i robusnog optimuma ($N = 100$). 16
4.1 Numerički rezultati optimalne nivelacije ceste za Slučaje A i B. 21

1. UVOD

Matematičko optimiranje i teorija sustava čine temelj suvremenog inženjerskog projektiranja, optimalnog vođenja industrijskih procesa te analize i sinteze složenih dinamičkih sustava [1, 2]. U inženjerskoj praksi projektant se kontinuirano susreće sa zahtjevima minimizacije troškova, mase, utroška energije ili odstupanja od željenih radnih stanja, uz istovremeno strogo poštivanje fizičkih, tehnoloških i sigurnosnih ograničenja.

S povijesnog i teorijskog stajališta, razvoj optimizacijskih metoda doživio je ključnu promjenu paradigme. Dok se u klasičnoj optimizaciji granica rješivosti povlačila između linearnih i nelinearnih problema, suvremena teorija postavlja temeljnu distinkciju između **konveksnih** i **nekonveksnih** problema [1, 3]. Kod konveksnih optimizacijskih problema svaki lokalni minimum ujedno je i globalni minimum, a postojanje nužnih i dovoljnih uvjeta optimalnosti (KKT uvjeti) omogućuje razvoj iznimno efikasnih, polinomijalno složenih algoritama unutrašnje točke (*interior-point methods*).

1.1. Taksonomija konveksnih optimizacijskih problema

U okviru ovog seminarskog rada analiziraju se četiri reprezentativne klase optimizacijskih problema i metoda:

1. **Linearno programiranje (LP)**: Minimizacija linearne funkcije cilja nad konveksnim poliedrom definiranom linearnim nejednakostima i jednakostima. Koristi se u strukturiranim problemima raspodjele resursa i diskretiziranim varijacijskim zadaćama.

2. **Kvadratno programiranje (QP)**: Minimizacija konveksne kvadratne funkcije cilja uz linearna ograničenja. Predstavlja osnovu za algoritme slijednog kvadratnog programiranja (SQP) i modelsko prediktivno upravljanje (MPC).

3. **Robusna optimizacija**: Deterministički pristup rješavanju optimizacijskih problema u prisutnosti parametarske nesigurnosti, gdje se zahtijeva dopustivost rješenja za sve moguće realizacije parametara unutar zadanog skupa nesigurnosti (najgori slučaj) [4].

4. **Semidefinitno programiranje (SDP) i linearne matrične nejednakosti (LMI)**: Minimizacija linearne funkcije nad presjekom afinih podprostora i stošca pozitivno semidefinitnih matrica. U teoriji automatskog upravljanja LMI pruža moćan matematički aparat za sintezu robusnih regulatora i dokazivanje stabilnosti sklopnih i nelinearnih sustava primjenom teorije Ljapunova [5, 6].

1.2. Struktura seminarskog rada

Rad je strukturiran kroz četiri samostalne, matematički i numerički rigorozno obrađene inženjerske cjeline:

- **Poglavlje 2 (Zadatak 1)** obrađuje problem kvadratnog programiranja s dva ograničenja nejednakosti. Provodi se provjera stroge konveksnosti preko Hesseove matrice, postavlja se Karush-Kuhn-Tuckerov (KKT) sustav te se analitički rješavaju sve 4 kombinacije aktivnih skupova. Također se izvodi Lagrangeova dualna funkcija, dokazuje jaka dualnost te se analizira osjetljivost optimalne vrijednosti na perturbacije ograničenja (cijene u sjeni).

- **Poglavlje 3 (Zadatak 2)** proširuje analizu na robusno kvadratno programiranje pod pretpostavkom intervalne nesigurnosti koeficijenata matrice ograničenja od $\pm 15\%$. Izvodi se egzaktni deterministički robusni ekvivalent na temelju teorije najgoreg slučaja iz 8. predavanja [3], rješava se dobiveni prošireni QP te se provodi Monte Carlo verifikacija na 100 slučajnih realizacija.

- **Poglavlje 4 (Zadatak 3)** postavlja varijacijski problem optimalne nivelacije uzdužnog profila ceste uz minimizaciju iskopa i nasipa te ograničenja na maksimalni nagib i maksimalnu zakrivljenost (brzinu promjene nagiba). Diskretizacijom konačnim razlikama i uvođenjem epigrafskih varijabli problem se prevodi u standardni LP oblik te se rješava za četiri različita scenarija ($N = 20, 100$, Slučaj A i B).

- **Poglavlje 5 (Zadatak 4)** bavi se hibridnim sklopnim sustavom s dva stabilna (Hurwitzova) moda. Dokazuje se otvoreni mehanizam destabilizacije uslijed periodičkog prespajanja dinamika preko monodromijske matrice. Zatim se formulira problem sinteze robusnog stanjskog regulatora putem zajedničke kvadratne funkcije Ljapunova (CQLF) i kongruentne transformacije u LMI formu, a dobiveni zatvoreni krug se verificira numeričkom simulacijom.

- **Poglavlje 6 (Zaključak)** daje sintezu dobivenih rezultata i komparativni osvrt na primijenjene optimizacijske metodologije.

2. KVADRATNO PROGRAMIRANJE, KKT UVJETI, DUALNOST I ANALIZA OSJETLJIVOSTI

2.1. Opis problema i provjera konveksnosti

Zadan je optimizacijski problem kvadratnog programiranja (engl. *Quadratic Programming* – QP) s dvije projektne varijable $x = [x_1, x_2]^T \in \mathbb{R}^2$ i dva ograničenja nejednakosti:

$$\min_{x \in \mathbb{R}^2} \quad f(x) = x_1^2 + 2x_2^2 - 0.3x_1x_2 + 2x_1 - 3x_2 \tag{2.1}$$

uz ograničenja:

$$g_1(x) = a_{11}x_1 + a_{12}x_2 + 10 \leq 0, \tag{2.2}$$
$$g_2(x) = a_{21}x_1 + a_{22}x_2 - 3 \leq 0, \tag{2.3}$$

gdje su nominalne numeričke vrijednosti koeficijenata:

$$a_{11} = -1, \quad a_{12} = -1, \quad a_{21} = 1, \quad a_{22} = -1. \tag{2.4}$$

Ograničenja u eksplicitnom obliku glase:

$$g_1(x) = -x_1 - x_2 + 10 \leq 0 \iff x_1 + x_2 \geq 10, \tag{2.5}$$
$$g_2(x) = x_1 - x_2 - 3 \leq 0 \iff x_1 - x_2 \leq 3. \tag{2.6}$$

2.1.1. Matrični kanonski zapis i dokaz stroge konveksnosti

Funkcija cilja $f(x)$ može se prikazati u simetričnom matričnom obliku:

$$f(x) = \frac{1}{2}x^T Q x + c^T x, \tag{2.7}$$

gdje su Hesseova matrica $Q = \nabla^2 f(x) \in \mathbb{R}^{2\times 2}$ i vektor linearnog dijela $c \in \mathbb{R}^2$ definirani kao:

$$Q = \begin{bmatrix} 2 & -0.3 \\ -0.3 & 4 \end{bmatrix}, \quad c = \begin{bmatrix} 2 \\ -3 \end{bmatrix}. \tag{2.8}$$

Uvrštavanjem se potvrđuje identitet:

$$\frac{1}{2}\begin{bmatrix} x_1 & x_2 \end{bmatrix}\begin{bmatrix} 2 & -0.3 \\ -0.3 & 4 \end{bmatrix}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 2 & -3 \end{bmatrix}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1^2 + 2x_2^2 - 0.3x_1x_2 + 2x_1 - 3x_2 \equiv f(x). \tag{2.9}$$

Da bi funkcija cilja $f(x)$ bila strogo konveksna na čitavom prostoru $\mathbb{R}^2$, nužno je i dovoljno da je Hesseova matrica Q simetrična i strogo pozitivno definitna ($Q \succ 0$). Svojstvene vrijednosti matrice Q određuju se iz karakterističnog polinoma:

$$\det(\lambda I - Q) = \det\begin{bmatrix} \lambda - 2 & 0.3 \\ 0.3 & \lambda - 4 \end{bmatrix} = (\lambda - 2)(\lambda - 4) - 0.09 = \lambda^2 - 6\lambda + 7.91 = 0. \tag{2.10}$$

Rješenja karakteristične jednadžbe iznose:

$$\lambda_{1,2} = \frac{6 \pm \sqrt{36 - 4 \cdot 7.91}}{2} = \frac{6 \pm \sqrt{4.36}}{2} \approx \frac{6 \pm 2.088061}{2}, \tag{2.11}$$

odnosno:

$$\lambda_1 \approx 1.955969 > 0, \quad \lambda_2 \approx 4.044031 > 0. \tag{2.12}$$

Budući da su obje svojstvene vrijednosti strogo pozitivne ($\lambda_i > 0$), matrica Q je pozitivno definitna ($Q \succ 0$), što dokazuje da je funkcija cilja $f(x)$ **strogo konveksna** [1].

2.1.2. Konveksnost dopustivog skupa i globalna optimalnost

Dopustivi skup $\mathcal{F} \subset \mathbb{R}^2$ definiran je presjekom dva poluprostora:

$$\mathcal{F} = \{x \in \mathbb{R}^2 \mid g_1(x) \leq 0,\ g_2(x) \leq 0\} = \{x \in \mathbb{R}^2 \mid Ax \leq b\}, \tag{2.13}$$

gdje su:

$$A = \begin{bmatrix} -1 & -1 \\ 1 & -1 \end{bmatrix}, \quad b = \begin{bmatrix} -10 \\ 3 \end{bmatrix}. \tag{2.14}$$

Budući da su funkcije ograničenja $g_1(x)$ i $g_2(x)$ afine (linearne), njihovi podnivo-skupovi su zatvoreni poluprostori, a presjek proizvoljnog broja konveksnih skupova je konveksan skup. Stoga je dopustivo područje $\mathcal{F}$ konveksan poliedar.

Budući da je funkcija cilja $f(x)$ strogo konveksna, a dopustivi skup $\mathcal{F}$ neprazan i konveksan, razmatrani problem je **konveksan optimizacijski problem**, što jamči postojanje **jedinstvenog globalnog minimuma** x^* koji ujedno zadovoljava Karush-Kuhn-Tuckerove (KKT) uvjete optimalnosti.

2.2. Lagrangeova funkcija i KKT uvjeti optimalnosti

Za problem (2.1)–(2.3) definiramo Lagrangeovu funkciju $\mathcal{L} : \mathbb{R}^2 \times \mathbb{R}^2 \to \mathbb{R}$:

$$\mathcal{L}(x, \mu) = f(x) + \mu_1 g_1(x) + \mu_2 g_2(x) = f(x) + \mu^T (Ax - b), \tag{2.15}$$

gdje su $\mu = [\mu_1, \mu_2]^T$ Lagrangeovi množitelji pridruženi nejednakostima.

Gradijenti funkcije cilja i funkcija ograničenja iznose:

$$\nabla f(x) = Qx + c = \begin{bmatrix} 2x_1 - 0.3x_2 + 2 \\ 4x_2 - 0.3x_1 - 3 \end{bmatrix}, \quad \nabla g_1(x) = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \quad \nabla g_2(x) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}. \tag{2.16}$$

Karush-Kuhn-Tuckerovi (KKT) uvjeti prvog reda za konveksan QP predstavljaju nužne i dovoljne uvjete globalne optimalnosti [1, 2]:

1. **Stacionarnost Lagrangeove funkcije**:

$$\nabla_x \mathcal{L}(x^*, \mu^*) = \nabla f(x^*) + \mu_1^* \nabla g_1(x^*) + \mu_2^* \nabla g_2(x^*) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \tag{2.17}$$

odnosno:

$$\begin{bmatrix} 2 & -0.3 \\ -0.3 & 4 \end{bmatrix} \begin{bmatrix} x_1^* \\ x_2^* \end{bmatrix} + \begin{bmatrix} 2 \\ -3 \end{bmatrix} + \mu_1^* \begin{bmatrix} -1 \\ -1 \end{bmatrix} + \mu_2^* \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \tag{2.18}$$

2. **Primarna dopustivost**:

$$g_1(x^*) = -x_1^* - x_2^* + 10 \leq 0, \quad g_2(x^*) = x_1^* - x_2^* - 3 \leq 0. \tag{2.19}$$

3. **Dualna dopustivost**:

$$\mu_1^* \geq 0, \quad \mu_2^* \geq 0. \tag{2.20}$$

4. **Komplementarno popuštanje**:

$$\mu_1^* \cdot (-x_1^* - x_2^* + 10) = 0, \quad \mu_2^* \cdot (x_1^* - x_2^* - 3) = 0. \tag{2.21}$$

2.3. Analitičko rješavanje KKT sustava (4 kombinacije aktivnih skupova)

Budući da imamo dva ograničenja nejednakosti, provodimo iscrpnu analizu svih $2^2 = 4$ mogućih kombinacija aktivnih i neaktivnih ograničenja.

2.3.1. Slučaj 1: Oba ograničenja neaktivna ($\mu_1 = 0, \mu_2 = 0$)

Ako nijedno ograničenje nije aktivno na granici, traži se stacionarna točka nesputane funkcije cilja:

$$\nabla f(x_0) = 0 \iff Qx_0 = -c \implies x_0 = -Q^{-1}c. \tag{2.22}$$

Inverz matrice Q iznosi:

$$Q^{-1} = \frac{1}{\det(Q)} \begin{bmatrix} 4 & 0.3 \\ 0.3 & 2 \end{bmatrix} = \frac{1}{7.91} \begin{bmatrix} 4 & 0.3 \\ 0.3 & 2 \end{bmatrix} = \frac{100}{791} \begin{bmatrix} 4 & 0.3 \\ 0.3 & 2 \end{bmatrix}. \tag{2.23}$$

Računamo komponente nesputanog minimuma x_0:

$$x_0 = -\frac{100}{791} \begin{bmatrix} 4 & 0.3 \\ 0.3 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ -3 \end{bmatrix} = -\frac{100}{791} \begin{bmatrix} 8 - 0.9 \\ 0.6 - 6 \end{bmatrix} = \begin{bmatrix} -\frac{710}{791} \\ \frac{540}{791} \end{bmatrix} \approx \begin{bmatrix} -0.897598 \\ 0.682680 \end{bmatrix}. \tag{2.24}$$

Uvrštavanjem točke x_0 u ograničenja provjeravamo primarnu dopustivost:

$$g_1(x_0) = -(-0.897598) - 0.682680 + 10 = 10.214918 > 0. \tag{2.25}$$

Budući da je $g_1(x_0) > 0$, nesputani optimum narušava primarno ograničenje te se **Slučaj 1 odbacuje kao primarno nedopustiv**.

2.3.2. Slučaj 2: Samo prvo ograničenje aktivno ($\mu_1 > 0, \mu_2 = 0$)

U ovom slučaju vrijedi $g_1(x) = 0 \implies x_1 + x_2 = 10$, dok je $\mu_2 = 0$. Uvjet stacionarnosti (2.17) svodi se na sustav tri linearne jednadžbe s tri nepoznanice (x_1, x_2, μ_1):

$$\begin{bmatrix} 2 & -0.3 & -1 \\ -0.3 & 4 & -1 \\ -1 & -1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \mu_1 \end{bmatrix} = \begin{bmatrix} -2 \\ 3 \\ -10 \end{bmatrix}. \tag{2.26}$$

Iz prve dvije jednadžbe izražavamo μ_1:

$$\mu_1 = 2x_1 - 0.3x_2 + 2, \tag{2.27}$$

$$\mu_1 = -0.3x_1 + 4x_2 - 3. \tag{2.28}$$

Izjednačavanjem desnih strana dobivamo:

$$2x_1 - 0.3x_2 + 2 = -0.3x_1 + 4x_2 - 3 \iff 2.3x_1 - 4.3x_2 + 5 = 0. \tag{2.29}$$

Uvrštavanjem relacije $x_2 = 10 - x_1$ iz aktivnog ograničenja $g_1(x) = 0$:

$$2.3x_1 - 4.3(10 - x_1) + 5 = 0 \iff 6.6x_1 - 43 + 5 = 0 \iff 6.6x_1 = 38. \tag{2.30}$$

Egzaktno analitičko rješenje glasi:

$$x_1^* = \frac{38}{6.6} = \frac{380}{66} = \frac{190}{33} \approx 5.757576, \tag{2.31}$$

$$x_2^* = 10 - x_1^* = 10 - \frac{190}{33} = \frac{140}{33} \approx 4.242424. \tag{2.32}$$

Lagrangeov množitelj μ_1^* iznosi:

$$\mu_1^* = 2\left(\frac{190}{33}\right) - 0.3\left(\frac{140}{33}\right) + 2 = \frac{380 - 42 + 66}{33} = \frac{404}{33} \approx 12.242424. \tag{2.33}$$

Provjera svih KKT uvjeta za Slučaj 2:

1. Dualna dopustivost: $\mu_1^* = \frac{404}{33} \approx 12.242424 > 0$ ✓
2. Primarna dopustivost za g_2:

$$g_2(x^*) = x_1^* - x_2^* - 3 = \frac{190}{33} - \frac{140}{33} - 3 = \frac{50}{33} - \frac{99}{33} = -\frac{49}{33} \approx -1.484848 < 0 \quad ✓ \tag{2.34}$$

3. Komplementarnost: $\mu_1^* g_1(x^*) = 0$ i $\mu_2^* g_2(x^*) = 0 \cdot (-1.4848) = 0$ ✓

Budući da su svi uvjeti zadovoljeni, točka $x^* = \left(\frac{190}{33}, \frac{140}{33}\right)$ s množiteljima $\mu^* = \left[\frac{404}{33}, 0\right]^T$

predstavlja **jedinstveni globalni optimum**.

Optimalna vrijednost funkcije cilja iznosi:

$$p^* = f(x^*) = \left(\frac{190}{33}\right)^2 + 2\left(\frac{140}{33}\right)^2 - 0.3\left(\frac{190}{33}\right)\left(\frac{140}{33}\right) + 2\left(\frac{190}{33}\right) - 3\left(\frac{140}{33}\right)$$
$$= \frac{2000}{33} \approx 60.606061. \tag{2.35}$$

2.3.3. Slučaj 3: Samo drugo ograničenje aktivno ($\mu_1 = 0, \mu_2 > 0$)

Postavljamo $g_2(x) = 0 \implies x_1 - x_2 = 3$ uz $\mu_1 = 0$. Sustav stacionarnosti daje:

$$\begin{bmatrix} 2 & -0.3 & 1 \\ -0.3 & 4 & -1 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \mu_2 \end{bmatrix} = \begin{bmatrix} -2 \\ 3 \\ 3 \end{bmatrix}. \tag{2.36}$$

Rješavanjem ovog sustava dobivamo:

$$x_1 = \frac{121}{54} \approx 2.240741, \quad x_2 = -\frac{41}{54} \approx -0.759259, \quad \mu_2 = -\frac{3623}{540} \approx -6.709259. \tag{2.37}$$

Provjera ograničenja $g_1(x)$:

$$g_1(x) = -2.240741 - (-0.759259) + 10 = 8.518519 > 0. \tag{2.38}$$

Budući da je $\mu_2 < 0$ (kršenje dualne dopustivosti) i $g_1(x) > 0$ (kršenje primarne dopustivosti), **Slučaj 3 se odbacuje**.

2.3.4. Slučaj 4: Oba ograničenja aktivna ($\mu_1 > 0, \mu_2 > 0$)

Aktivnost oba ograničenja definira sjecište pravaca:

$$\begin{cases} -x_1 - x_2 = -10 \\ x_1 - x_2 = 3 \end{cases} \implies x_1 = 6.5, \quad x_2 = 3.5. \tag{2.39}$$

Uvrštavanjem točke $x = [6.5, 3.5]^T$ u uvjet stacionarnosti $Qx + c + A^T\mu = 0$:

$$\begin{bmatrix} -1 & 1 \\ -1 & -1 \end{bmatrix} \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} = -\begin{bmatrix} 2(6.5) - 0.3(3.5) + 2 \\ 4(3.5) - 0.3(6.5) - 3 \end{bmatrix} = -\begin{bmatrix} 13.95 \\ 9.05 \end{bmatrix}. \tag{2.40}$$

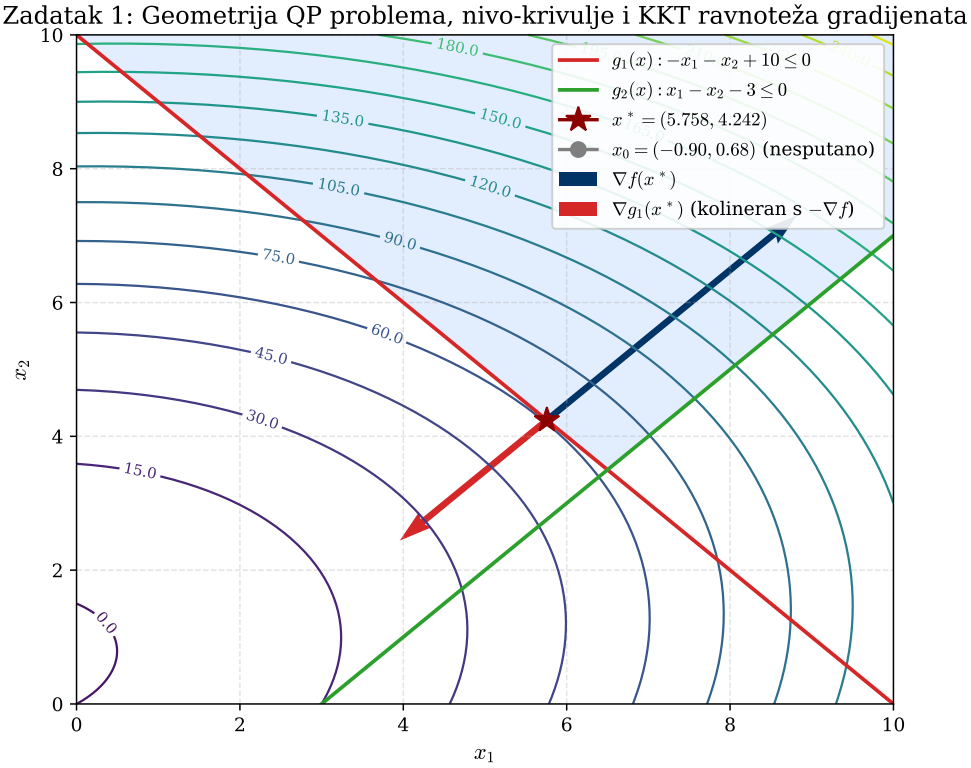
Rješavanjem 2×2 sustava za množitelje:

$$\mu_1 = 11.50 > 0, \quad \mu_2 = -2.45 < 0. \tag{2.41}$$

Budući da je $\mu_2 = -2.45 < 0$, narušen je uvjet dualne dopustivosti ($\mu_2 \geq 0$). Prema tome, **Slučaj 4 se odbacuje**.

2.4. Geometrijska interpretacija i ravnoteža gradijenata

Na slici 2.1 prikazana je geometrija QP problema u ravnini (x_1, x_2). Dopustivo područje $\mathcal{F}$ osjenčano je plavom bojom, eliptične nivo-krivulje prikazuju funkciju cilja $f(x)$, a zvjezdicom je označen optimalni vektor x^*.



Slika 2.1. Geometrijski prikaz dopustivog skupa $\mathcal{F}$, nivo-krivulja funkcije cilja $f(x)$ i vektora gradijenata u KKT točki x^*.

U optimalnoj točki $x^* = (5.758, 4.242)$ gradijent funkcije cilja i gradijent aktivnog ograničenja iznose:

$$\nabla f(x^*) = \begin{bmatrix} 12.242424 \\ 12.242424 \end{bmatrix}, \quad \nabla g_1(x^*) = \begin{bmatrix} -1 \\ -1 \end{bmatrix}. \tag{2.42}$$

Uočava se savršena kolinearnost suprotnog smjera:

$$\nabla f(x^*) + \mu_1^* \nabla g_1(x^*) = \begin{bmatrix} 12.242424 \\ 12.242424 \end{bmatrix} + 12.242424 \begin{bmatrix} -1 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \tag{2.43}$$

Fizička interpretacija ovog uvjeta odgovara ravnoteži sila: gradijent funkcije cilja $\nabla f(x^*)$ teži pomaknuti točku prema unutrašnjosti (nesputanom minimumu x_0), no nailazi na reakciju veze

(graničnu silu) normalnog vektora $\nabla g_1(x^*)$ proporcionalnu intenzitetu Lagrangeovog množitelja $\mu_1^* = 12.2424$.

2.5. Numerička verifikacija u programskim paketima

Problem je numerički verificiran u programskim alatima MATLAB (`quadprog`, YALMIP) i Python (`scipy.optimize`, `cvxpy`). U tablici 2.1 prikazana je usporedba analitičkih i numeričkih rezultata.

Tablica 2.1. Usporedba analitičkih i numeričkih rezultata za Zadatak 1.

Veličina	Analitička vrijednost	MATLAB / Python	Apsolutna pogreška	Status
x_1^*	$190/33 \approx 5.757576$	5.757576	$< 10^{-8}$	Egzaktno
x_2^*	$140/33 \approx 4.242424$	4.242424	$< 10^{-8}$	Egzaktno
μ_1^*	$404/33 \approx 12.242424$	12.242424	$< 10^{-8}$	Egzaktno
μ_2^*	0.000000	0.000000	0.00	Neaktivno
$p^* = f(x^*)$	$2000/33 \approx 60.606061$	60.606061	$< 10^{-8}$	Egzaktno
$d^* = g(\mu^*)$	$2000/33 \approx 60.606061$	60.606061	$< 10^{-8}$	Jaka dualnost

2.6. Lagrangeova dualnost i dokaz jake dualnosti

Lagrangeova dualna funkcija $g(\mu)$ definirana je kao infimum Lagrangeove funkcije po $x \in \mathbb{R}^2$ [1, 3]:

$$g(\mu) = \inf_{x \in \mathbb{R}^2} \mathcal{L}(x, \mu) = \inf_{x \in \mathbb{R}^2} \left[\frac{1}{2} x^T Q x + (c + A^T \mu)^T x - b^T \mu \right]. \tag{2.44}$$

Budući da je $Q \succ 0$, funkcija unutar infimuma je strogo konveksna po x, a minimum se postiže poništavanjem gradijenta $\nabla_x \mathcal{L} = Qx + c + A^T \mu = 0$:

$$x^*(\mu) = -Q^{-1}(c + A^T \mu). \tag{2.45}$$

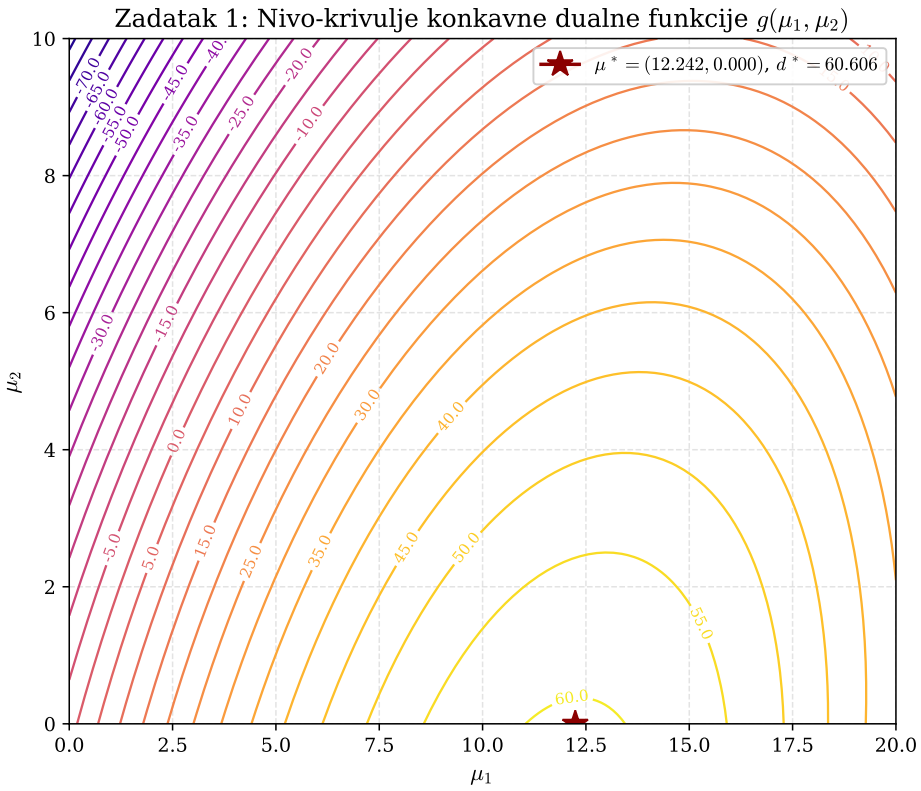
Uvrštavanjem $x^*(\mu)$ natrag u Lagrangeovu funkciju dobiva se eksplicitni analitički oblik dualne funkcije:

$$\begin{aligned} g(\mu) &= \frac{1}{2}(-Q^{-1}(c + A^T\mu))^T Q(-Q^{-1}(c + A^T\mu)) + (c + A^T\mu)^T(-Q^{-1}(c + A^T\mu)) - b^T\mu \\ &= -\frac{1}{2}(c + A^T\mu)^T Q^{-1}(c + A^T\mu) - b^T\mu. \end{aligned} \tag{2.46}$$

Budući da je matrica $-Q^{-1}$ negativno definitna, dualna funkcija $g(\mu)$ je konkavna kvadratna funkcija po $\mu = [\mu_1, \mu_2]^T$.

Lagrangeov dualni problem glasi:

$$\max_{\mu \in \mathbb{R}^2} \quad g(\mu) \quad \text{uz} \quad \mu_1 \geq 0,\ \mu_2 \geq 0. \tag{2.47}$$



Slika 2.2. Nivo-krivulje konkavne Lagrangeove dualne funkcije $g(\mu_1, \mu_2)$ i optimalna dualna točka $\mu^* = (12.242, 0.000)$.

Slika 2.2 prikazuje nivo-krivulje dualne funkcije $g(\mu_1, \mu_2)$. Numeričkim rješavanjem pomoću funkcije `fmincon` (minimizacija funkcije $-g(\mu)$ uz $\mu \geq 0$) dobiva se:

$$\mu^* = \begin{bmatrix} 12.242424 \\ 0.000000 \end{bmatrix}, \quad d^* = g(\mu^*) = 60.606061. \tag{2.48}$$

2.6.1. Provjera Slaterovog uvjeta i jaka dualnost

Slaterov teorem o jakoj dualnosti jamči da za konveksan problem s afinim ograničenjima vrijedi nulti dualni procjep ($p^* = d^*$) ako postoji točka x_{int} u strogoj unutrašnjosti dopustivog skupa [1]. Odabirom točke $x_{\text{int}} = [7, 6]^T$ imamo:

$$g_1(x_{\text{int}}) = -7 - 6 + 10 = -3 < 0, \quad g_2(x_{\text{int}}) = 7 - 6 - 3 = -2 < 0. \tag{2.49}$$

Budući da je Slaterov uvjet strogo zadovoljen, vrijedi **jaka dualnost**:

$$\gamma = p^* - d^* = 60.606061 - 60.606061 = 0. \tag{2.50}$$

2.7. Analiza osjetljivosti i perturbacija ograničenja

Teorem o osjetljivosti u nelinearnom programiranju povezuje optimalne Lagrangeove množitelje s parcijalnim derivacijama optimalne vrijednosti funkcije cilja po desnim stranama ograničenja [1, 7].

Neka je $p^*(u)$ funkcija optimalne vrijednosti u ovisnosti o perturbacijskom vektoru $u = [u_1, u_2]^T$, gdje su ograničenja perturbirana u obliku $Ax \leq b + u$:

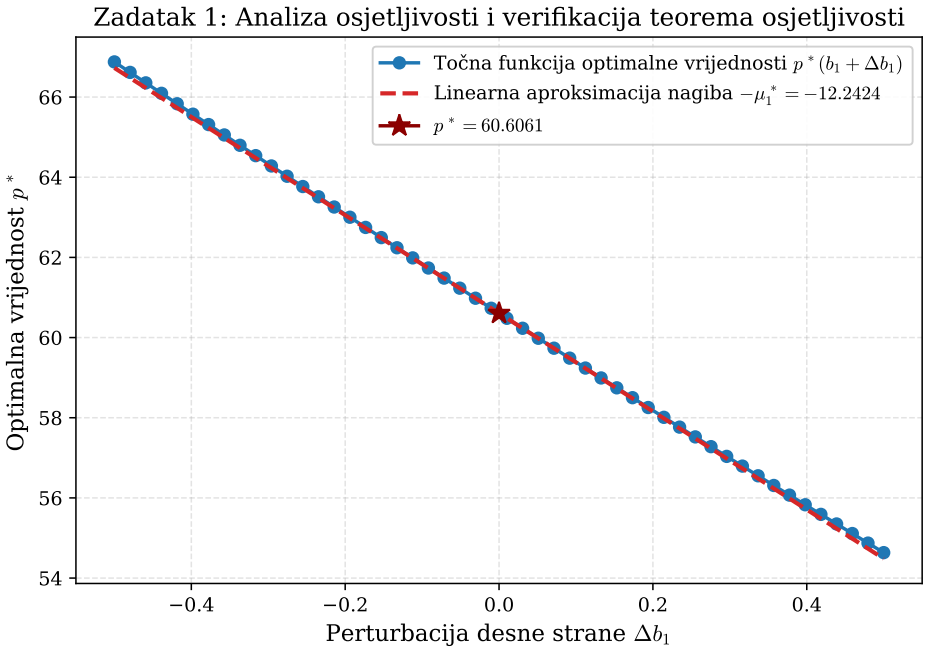
$$p^*(u) = \inf\{f(x) \mid Ax \leq b + u\}. \tag{2.51}$$

Prema teoremu o osjetljivosti vrijedi:

$$\frac{\partial p^*}{\partial b_i} = -\mu_i^*, \quad i = 1, 2. \tag{2.52}$$

Za naša ograničenja dobivamo:

$$\frac{\partial p^*}{\partial b_1} = -\mu_1^* = -\frac{404}{33} \approx -12.242424, \quad \frac{\partial p^*}{\partial b_2} = -\mu_2^* = 0. \tag{2.53}$$



Slika 2.3. Funkcija optimalne vrijednosti $p^*(b_1 + \Delta b_1)$ u usporedbi s linearnom aproksimacijom nagiba $-\mu_1^*$.

2.7.1. Inženjerska i ekonomska interpretacija (cijene u sjeni)

Množitelj $\mu_1^* = 12.2424$ ima ulogu **cijene u sjeni** (*shadow price*):

- Ako se desna strana prvog ograničenja b_1 poveća za mali iznos $\Delta b_1 > 0$ (čime se

ograničenje $-x_1 - x_2 \leq -10 + \Delta b_1$ relaksira), optimalna vrijednost p^* se **smanjuje** po stopi od približno $12.2424 \cdot \Delta b_1$.

- Ako se desna strana drugog ograničenja b_2 perturbira, budući da je g_2 neaktivno ($\mu_2^* = 0$), to nema nikakvog utjecaja na optimalno rješenje prvog reda ($\frac{\partial p^*}{\partial b_2} = 0$).

Numerička verifikacija provedena je s perturbacijskim korakom $\Delta b_1 = 10^{-4}$:

$$\left(\frac{\Delta p^*}{\Delta b_1}\right)_{\text{num}} = \frac{p^*(b_1 + 10^{-4}) - p^*(b_1)}{10^{-4}} = -12.242357, \tag{2.54}$$

što daje odstupanje od analitičke derivacije manje od 6.75×10^{-5}, čime je teorem osjetljivosti u potpunosti verificiran.

3. ROBUSNO KVADRATNO PROGRAMIRANJE POD INTERVALNOM NESIGURNOŠĆU

3.1. Koncept robusne optimizacije i definicija skupa nesigurnosti

U stvarnim inženjerskim primjenama parametri optimizacijskog modela (koeficijenti modela procesa, fizičke konstante, otpori, koeficijenti matrice ograničenja) rijetko su egzaktno poznati. Oni podliježu mjernim pogreškama, tolerancijama izrade i promjenama radnih uvjeta. U klasičnoj (nominalnoj) optimizaciji pretpostavlja se da su parametri deterministički fiksirani, što može rezultirati rješenjima koja su izrazito osjetljiva na poremećaje te postaju nedopustiva već pri minimalnim odstupanjima parametara [3, 4].

Robusna optimizacija pristupa ovom problemu formuliranjem zahtjeva da optimalno rješenje mora zadovoljiti sva ograničenja za **sve** moguće realizacije nesigurnih parametara unutar unaprijed definiranog skupa nesigurnosti $\mathcal{U}$ (koncept najgoreg slučaja – engl. *worst-case approach*) [4].

Za optimizacijski problem iz Zadatka 1 pretpostavljamo da su koeficijenti matrice ograničenja a_{ij}, $i, j \in \{1, 2\}$, nesigurni te da se njihove stvarne vrijednosti nalaze u intervalu od $\pm 15\%$ oko nominalnih vrijednosti:

$$a_{ij,\text{stvarno}} \in [0.85 \cdot a_{ij}^0,\ 1.15 \cdot a_{ij}^0], \quad \forall i, j \in \{1, 2\}. \tag{3.1}$$

Za pojedina ograničenja nominalni koeficijenti i pripadajući intervali nesigurnosti glase:

- **Prvo ograničenje** ($a_{11}^0 = -1, a_{12}^0 = -1, b_1 = -10$):

$$a_{11} \in [-1.15, -0.85], \quad a_{12} \in [-1.15, -0.85], \tag{3.2}$$

što definira pravokutni skup nesigurnosti $\mathcal{U}_1 \subset \mathbb{R}^2$:

$$\mathcal{U}_1 = \{a_1 \in \mathbb{R}^2 \mid -1.15 \leq a_{11} \leq -0.85,\ -1.15 \leq a_{12} \leq -0.85\}. \tag{3.3}$$

- **Drugo ograničenje** ($a_{21}^0 = 1, a_{22}^0 = -1, b_2 = 3$):

$$a_{21} \in [0.85, 1.15], \quad a_{22} \in [-1.15, -0.85], \tag{3.4}$$

što definira skup nesigurnosti $\mathcal{U}_2 \subset \mathbb{R}^2$:

$$\mathcal{U}_2 = \{a_2 \in \mathbb{R}^2 \mid 0.85 \leq a_{21} \leq 1.15,\ -1.15 \leq a_{22} \leq -0.85\}. \tag{3.5}$$

3.2. Egzaktna derivacija deterministčkog robusnog ekvivalenta

Polazni robusni problem kvadratnog programiranja formulira se kao semi-beskonačni optimizacijski problem:

$$\min_{x \in \mathbb{R}^2} \quad \frac{1}{2} x^T Q x + c^T x \tag{3.6}$$

uz ograničenja:

$$\max_{a_1 \in \mathcal{U}_1} (a_{11} x_1 + a_{12} x_2) \leq -10, \tag{3.7}$$

$$\max_{a_2 \in \mathcal{U}_2} (a_{21} x_1 + a_{22} x_2) \leq 3. \tag{3.8}$$

Prema teoriji robusne konveksne optimizacije [3, 4], za poliedarski (intervalni) skup nesigurnosti $\mathcal{U}_i = \text{conv}(\{v_i^{(1)}, \ldots, v_i^{(K)}\})$, maksimalna vrijednost linearne funkcije $a_i^T x$ po konveksnom poliedru $\mathcal{U}_i$ uvijek se postiže u jednom od njegovih ekstremnih vrhova (*vertices*):

$$\max_{a_i \in \mathcal{U}_i} a_i^T x = \max_{k \in \{1,\ldots,K\}} (v_i^{(k)})^T x. \tag{3.9}$$

Stoga je semi-beskonačno ograničenje $\max_{a_i \in \mathcal{U}_i} a_i^T x \leq b_i$ **egzaktno ekvivalentno** sustavu od K konačnih linearnih nejednakosti:

$$(v_i^{(k)})^T x \leq b_i, \quad \forall k \in \{1, \ldots, K\}. \tag{3.10}$$

Za svaki od 2D pravokutnika $\mathcal{U}_1$ i $\mathcal{U}_2$ imamo po $2^2 = 4$ vrha, što ukupno daje $4 + 4 = 8$ deterministčkih linearnih nejednakosti:

1. **Vrhovi skupa nesigurnosti $\mathcal{U}_1$ (prvo ograničenje)**:

$$-1.15x_1 - 1.15x_2 \leq -10, \tag{3.11}$$
$$-1.15x_1 - 0.85x_2 \leq -10, \tag{3.12}$$
$$-0.85x_1 - 1.15x_2 \leq -10, \tag{3.13}$$
$$-0.85x_1 - 0.85x_2 \leq -10. \tag{3.14}$$

2. **Vrhovi skupa nesigurnosti $\mathcal{U}_2$ (drugo ograničenje)**:

$$0.85x_1 - 1.15x_2 \leq 3, \tag{3.15}$$
$$0.85x_1 - 0.85x_2 \leq 3, \tag{3.16}$$
$$1.15x_1 - 1.15x_2 \leq 3, \tag{3.17}$$
$$1.15x_1 - 0.85x_2 \leq 3. \tag{3.18}$$

Matrični oblik deterministčkog robusnog ekvivalenta glasi:

$$\min_{x\in\mathbb{R}^2} \quad \frac{1}{2}x^T Q x + c^T x \quad \text{uz} \quad A_{\text{rob}} x \leq b_{\text{rob}}, \tag{3.19}$$

gdje je $A_{\text{rob}} \in \mathbb{R}^{8\times 2}$ matrica sastavljena od svih 8 vektora vrhova, a $b_{\text{rob}} = [-10,-10,-10,-10,3,3,3,3]^T \in \mathbb{R}^8$.

3.3. Analitičko rješenje robusnog QP-a

Za područje pozitivnog kvadranta ($x_1 \geq 0, x_2 \geq 0$), najrestriktivnije (najgore) nejednakosti među vrhovima određuju se analizom predznaka:

- Za prvo ograničenje: budući da su koeficijenti negativni, najmanje negativan izraz na lijevoj strani postiže se za $a_{11} = -0.85$ i $a_{12} = -0.85$:

$$-0.85x_1 - 0.85x_2 \leq -10 \iff x_1 + x_2 \geq \frac{10}{0.85} = \frac{200}{17} \approx 11.764706. \tag{3.20}$$

- Za drugo ograničenje: najgori slučaj maksimizira $a_{21}x_1 + a_{22}x_2$, što se postiže za maksimalni koeficijent $a_{21} = 1.15$ i najmanje negativan $a_{22} = -0.85$:

$$1.15x_1 - 0.85x_2 \leq 3. \tag{3.21}$$

U optimalnoj točki robusnog problema oba najgora ograničenja (3.20) i (3.21) postaju

aktivna na granici. Postavljanjem sustava jednadžbi:

$$\begin{cases} 0.85x_1 + 0.85x_2 = 10 \\ 1.15x_1 - 0.85x_2 = 3 \end{cases} \tag{3.22}$$

Zbrajanjem jednadžbi eliminira se varijabla x_2:

$$(0.85 + 1.15)x_1 = 10 + 3 \iff 2.0x_1 = 13 \implies x^*_{1,\text{rob}} = \frac{13}{2} = 6.500000. \tag{3.23}$$

Uvrštavanjem u prvu jednadžbu izračunava se $x^*_{2,\text{rob}}$:

$$0.85(6.5)+0.85x_2 = 10 \iff 5.525+0.85x_2 = 10 \iff 0.85x_2 = 4.475 \implies x^*_{2,\text{rob}} = \frac{4.475}{0.85} = \frac{179}{34} \approx 5.26 \tag{3.24}$$

Optimalna robusna točka u zatvorenom analitičkom obliku iznosi:

$$x^*_{\text{rob}} = \begin{bmatrix} 6.500000 \\ \frac{179}{34} \end{bmatrix} \approx \begin{bmatrix} 6.500000 \\ 5.264706 \end{bmatrix}. \tag{3.25}$$

Vrijednost funkcije cilja u robusnom optimumu iznosi:

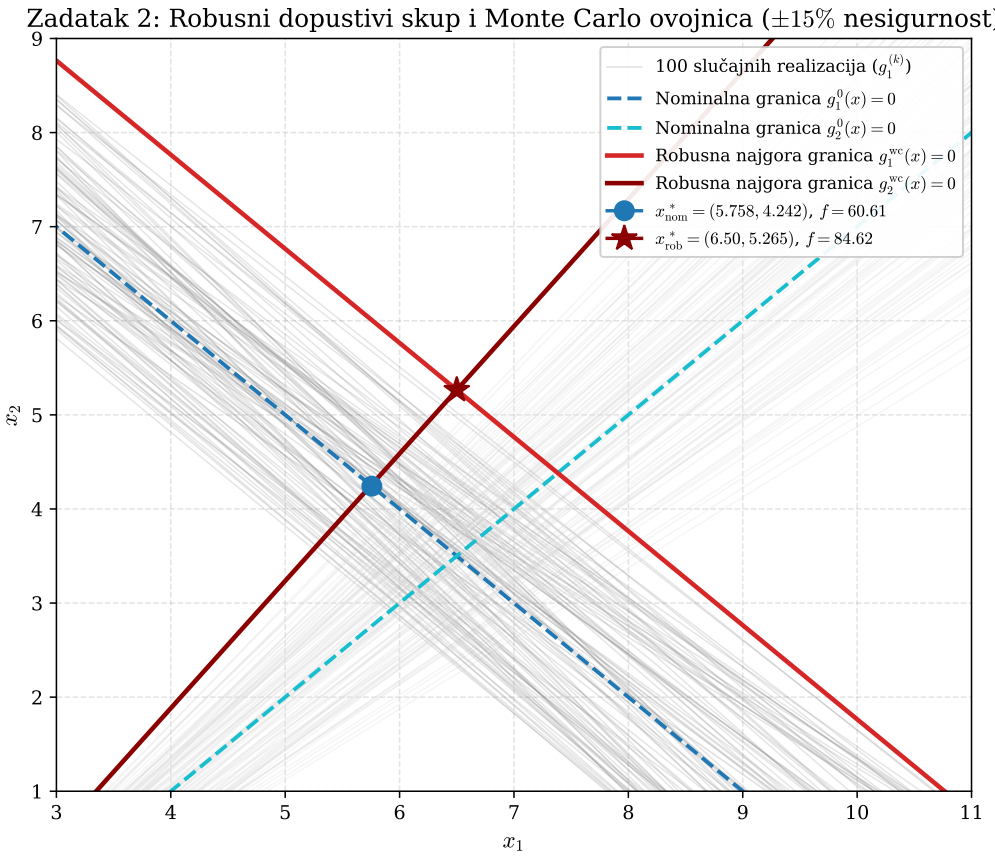
$$\begin{aligned} f(x^*_{\text{rob}}) &= 6.5^2 + 2\left(\frac{179}{34}\right)^2 - 0.3(6.5)\left(\frac{179}{34}\right) + 2(6.5) - 3\left(\frac{179}{34}\right) \\ &= \frac{978253}{11560} \approx 84.623962. \end{aligned} \tag{3.26}$$

Numeričko rješavanje pomoću MATLAB funkcije `quadprog` i Python modula `scipy.optimize` potvrđuje analitičko rješenje uz odstupanje manje od 7.05×10^{-9}.

3.4. Monte Carlo analiza dopustivosti i vizualizacija

Kako bi se empirijski verificirala robusnost predloženog rješenja, provedena je Monte Carlo simulacija s $N_{\text{MC}} = 100$ slučajnih realizacija matrica ograničenja $A^{(k)}$, gdje su elementi jednoliko distribuirani:

$$a^{(k)}_{ij} \sim \mathcal{U}(0.85a^0_{ij},\ 1.15a^0_{ij}), \quad k = 1, \ldots, 100. \tag{3.27}$$



Slika 3.1. Robusni dopustivi skup, nominalne granice i Monte Carlo ovojnica dobivena iz 100 slučajnih realizacija parametara nesigurnosti.

Slika 3.1 prikazuje geometrijski odnos:

- Tanke sive linije prikazuju granice ograničenja za 100 slučajnih realizacija.
- Isprekidane plave linije prikazuju nominalna ograničenja (g_1^0, g_2^0).
- Puna crvena linija označava ovojnicu najgoreg slučaja (robusne granice).
- Plavi krug označava nominalno rješenje $x^*_{\text{nom}} = (5.758, 4.242)$.
- Crvena zvjezdica označava robusno rješenje $x^*_{\text{rob}} = (6.500, 5.265)$.

Rezultati Monte Carlo provjere dopustivosti prikazani su u tablici 3.1.

Tablica 3.1. Monte Carlo provjera dopustivosti nominalnog i robusnog optimuma ($N = 100$).

Optimum	Broj kršenja ograničenja	Stopa nedopustivosti	Robusni status
Nominalni x^*_{nom}	57 / 100	57.0%	**Rizično** (često nedopustivo)
Robusni x^*_{rob}	0 / 100	0.0%	**100% Dopustivo (Zajamčeno)**

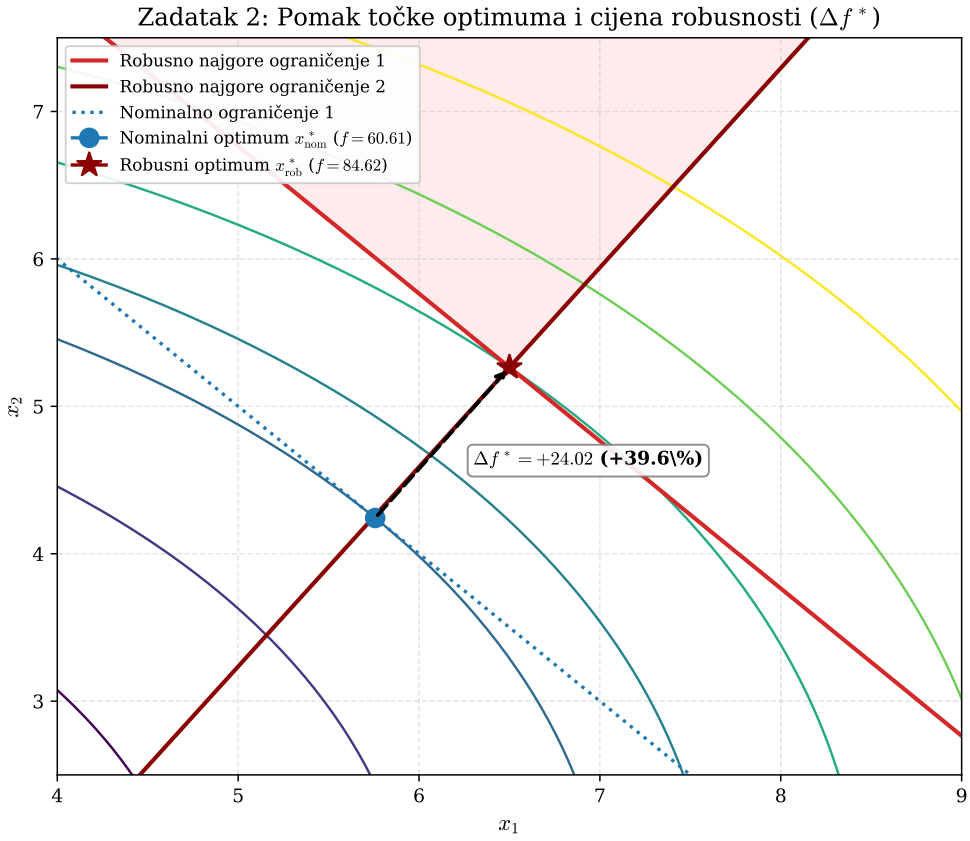
Uočava se da nominalno rješenje x^*_{nom} krši ograničenja u čak 57% slučajnih realizacija jer leži točno na nominalnoj granici. Suprotno tome, robusno rješenje x^*_{rob} leži unutar presjeka svih mogućih dopustivih skupova te posjeduje 100% pouzdanost.

3.5. Cijena robusnosti (*Price of Robustness*)

Uvođenje zahtjeva za robusnošću neumitno povlači određenu konzervativnost, što se u teoriji optimizacije naziva **cijenom robusnosti** (*Price of Robustness*) [4]. Ona se definira kao apsolutni i relativni porast optimalne vrijednosti funkcije cilja:

$$\Delta f^* = f(x^*_{\text{rob}}) - f(x^*_{\text{nom}}) = 84.623962 - 60.606061 = 24.017901, \tag{3.28}$$

$$\Delta f^*_{\%} = \frac{f(x^*_{\text{rob}}) - f(x^*_{\text{nom}})}{f(x^*_{\text{nom}})} \cdot 100\% = +39.63\%. \tag{3.29}$$



Slika 3.2. Nivo-krivulje funkcije cilja, pomak točke optimuma i geometrijska vizualizacija cijene robusnosti Δf^*.

Slika 3.2 prikazuje pomak točke optimuma sa x^*_{nom} na x^*_{rob}. Povećanje troška od 39.63% predstavlja inženjersku premiju osiguranja koja jamči apsolutnu operativnu sigurnost i izostanak kršenja ograničenja pod svim mogućim varijacijama parametara unutar definiranog $\pm 15\%$ koridora nesigurnosti.

4. OPTIMIZACIJSKA NIVELACIJA UZDUŽNOG PROFILA CESTE PRIMJENOM LINEARNOG PROGRAMIRANJA

4.1. Kontinuirana varijacijska formulacija problema

U građevinarstvu i prometnom inženjerstvu projektiranje uzdužnog profila prometnice predstavlja temeljni optimizacijski zadatak. Cilj je odrediti visinsku trasu ceste $y(x)$ koja minimizira ukupne zemljane radove (volumen iskopa i nasipa), uz istovremeno strogo zadovoljavanje prometno-tehničkih standarda: maksimalnog uzdužnog nagiba (sposobnost savladavanja uspona vozila) i maksimalne zakrivljenosti trase (udobnost vožnje i ograničenje vertikalnih akceleracija) [3].

Neka je L horizontalna duljina dionice ceste ($x \in [0, L]$), a $h(x)$ poznata prirodna visina terena. Problem se kontinuirano formulira kao varijacijski optimizacijski problem:

$$\min_{y(x)} \quad J[y] = \int_0^L |y(x) - h(x)|\, dx \tag{4.1}$$

uz ograničenja:

$$|y'(x)| \leq b_1, \quad \forall x \in [0, L], \tag{4.2}$$

$$|y''(x)| \leq b_2, \quad \forall x \in [0, L], \tag{4.3}$$

$$y(0) = a, \quad y(L) = b. \tag{4.4}$$

Zadani parametri modela su:

$$L = 10 \text{ m}, \quad h(x) = 0.0053x^4 - 0.095x^3 + 0.48x^2 - 0.3x + 1, \tag{4.5}$$

$$a = h(0) = 1 \text{ m}, \quad b = h(L) = 4 \text{ m}. \tag{4.6}$$

Razmatraju se dva skupa parametara:

- **Slučaj A**: $b_1 = 0.5$ (maksimalni nagib), $b_2 = 0.5$ m^{-1} (maksimalna zakrivljenost).
- **Slučaj B**: $b_1 = 0.5$ (maksimalni nagib), $b_2 = 0.2$ m^{-1} (stroži uvjet udobnosti vožnje).

4.2. Diskretizacija konačnim razlikama

Područje $[0, L]$ diskretizira se s N jednakih podintervala duljine $\Delta x = L/N$, čime se dobiva mreža od $N + 1$ čvorova:

$$x_i = i \cdot \Delta x, \quad i = 0, 1, \ldots, N, \quad \text{pri čemu je } x_0 = 0,\ x_N = L. \tag{4.7}$$

Vektor visina terena u čvorovima označavamo s $h = [h_0, h_1, \ldots, h_N]^T \in \mathbb{R}^{N+1}$, gdje je $h_i = h(x_i)$.

Vektor nepoznatih visina nivelete ceste u diskretnim čvorovima je $y = [y_0, y_1, \ldots, y_N]^T \in \mathbb{R}^{N+1}$.

4.2.1. Aproksimacija prve i druge derivacije

Prema uputama zadatka, nagib ceste u čvorovima aproksimira se prvom unazadnom podijeljenom razlikom:

$$y'(x_i) \approx \nabla y_i = \frac{y_i - y_{i-1}}{\Delta x}, \quad i = 1, \ldots, N. \tag{4.8}$$

Brzina promjene nagiba (zakrivljenost) aproksimira se drugom podijeljenom razlikom:

$$y''(x_i) \approx \nabla^2 y_i = \frac{\nabla y_i - \nabla y_{i-1}}{\Delta x} = \frac{y_i - 2y_{i-1} + y_{i-2}}{\Delta x^2}, \quad i = 2, \ldots, N. \tag{4.9}$$

U matričnom zapisu diferencijalni operatori glase:

$$\nabla y = D_1 y \in \mathbb{R}^N, \quad \nabla^2 y = D_2 y \in \mathbb{R}^{N-1}, \tag{4.10}$$

gdje su matrice konačnih razlika $D_1 \in \mathbb{R}^{N\times(N+1)}$ i $D_2 \in \mathbb{R}^{(N-1)\times(N+1)}$ definirane kao:

$$D_1 = \frac{1}{\Delta x}\begin{bmatrix} -1 & 1 & 0 & \ldots & 0 & 0 \\ 0 & -1 & 1 & \ldots & 0 & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots & \vdots \\ 0 & 0 & \ldots & -1 & 1 & 0 \\ 0 & 0 & \ldots & 0 & -1 & 1 \end{bmatrix}, \tag{4.11}$$

$$D_2 = \frac{1}{\Delta x^2}\begin{bmatrix} 1 & -2 & 1 & 0 & \ldots & 0 & 0 \\ 0 & 1 & -2 & 1 & \ldots & 0 & 0 \\ \vdots & \vdots & \ddots & \ddots & \ddots & \vdots & \vdots \\ 0 & 0 & \ldots & 1 & -2 & 1 & 0 \\ 0 & 0 & \ldots & 0 & 1 & -2 & 1 \end{bmatrix}. \tag{4.12}$$

4.3. Transformacija u standardni oblik linearnog programa (LP)

Diskretizirani integralni kriterij glasi:

$$J_{\text{disc}}[y] = \Delta x \sum_{i=0}^{N} |y_i - h_i|. \tag{4.13}$$

Zbog prisutnosti nelinearnog operatora apsolutne vrijednosti ($|y_i - h_i|$), problem se ne može direktno rješavati linearnim metodama. Međutim, primjenom metode epigrafskih pomoćnih varijabli (engl. *slack variables*) $z_i \geq |y_i - h_i|$, problem se egzaktno prevodi u standardni linearni program (LP) [1, 2].

Za svaki čvor $i = 0, \ldots, N$ nejednakost $z_i \geq |y_i - h_i|$ ekvivalentna je paru linearnih nejednakosti:

$$y_i - z_i \leq h_i, \tag{4.14}$$

$$-y_i - z_i \leq -h_i. \tag{4.15}$$

Prošireni vektor optimizacijskih varijabli $\theta \in \mathbb{R}^{2N+2}$ definira se kao:

$$\theta = \begin{bmatrix} y \\ z \end{bmatrix} = \begin{bmatrix} y_0 & y_1 & \ldots & y_N & z_0 & z_1 & \ldots & z_N \end{bmatrix}^T. \tag{4.16}$$

Funkcija cilja linearnog programa glasi:

$$\min_{\theta \in \mathbb{R}^{2N+2}} \quad f_{\text{LP}}^T \theta = \Delta x \sum_{i=0}^{N} z_i = \begin{bmatrix} \mathbf{0}_{1\times(N+1)} & \Delta x \cdot \mathbf{1}_{1\times(N+1)} \end{bmatrix} \begin{bmatrix} y \\ z \end{bmatrix}. \tag{4.17}$$

4.3.1. Struktura matrice nejednakosti $A_{\text{ineq}}\theta \leq b_{\text{ineq}}$

Sustav linearnih nejednakosti objedinjuje tri grupe fizikalnih ograničenja:

1. **Epigrafska ograničenja apsolutnog odstupanja** ($2(N+1)$ nejednakosti):

$$\begin{bmatrix} I_{N+1} & -I_{N+1} \\ -I_{N+1} & -I_{N+1} \end{bmatrix} \begin{bmatrix} y \\ z \end{bmatrix} \leq \begin{bmatrix} h \\ -h \end{bmatrix}. \tag{4.18}$$

2. **Ograničenja nagiba** ($2N$ nejednakosti):

$$\begin{bmatrix} D_1 & \mathbf{0}_{N\times(N+1)} \\ -D_1 & \mathbf{0}_{N\times(N+1)} \end{bmatrix} \begin{bmatrix} y \\ z \end{bmatrix} \leq \begin{bmatrix} b_1\mathbf{1}_N \\ b_1\mathbf{1}_N \end{bmatrix}. \tag{4.19}$$

3. **Ograničenja zakrivljenosti** ($2(N-1)$ nejednakosti):

$$\begin{bmatrix} D_2 & \mathbf{0}_{(N-1)\times(N+1)} \\ -D_2 & \mathbf{0}_{(N-1)\times(N+1)} \end{bmatrix} \begin{bmatrix} y \\ z \end{bmatrix} \leq \begin{bmatrix} b_2\mathbf{1}_{N-1} \\ b_2\mathbf{1}_{N-1} \end{bmatrix}. \tag{4.20}$$

Ukupan broj linearnih nejednakosti u matrici A_{ineq} iznosi:

$$N_{\text{ineq}} = 2(N+1) + 2N + 2(N-1) = 6N. \tag{4.21}$$

4.3.2. Struktura matričnih jednakosti $A_{\text{eq}}\theta = b_{\text{eq}}$

Rubni uvjeti u točkama $x = 0$ i $x = L$ zapisuju se kao sustav od 2 linearne jednakosti:

$$\begin{bmatrix} 1 & 0 & \dots & 0 & \mathbf{0}_{1\times(N+1)} \\ 0 & \dots & 0 & 1 & \mathbf{0}_{1\times(N+1)} \end{bmatrix} \begin{bmatrix} y \\ z \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \end{bmatrix}. \tag{4.22}$$

Donja granica za varijable je $z_i \geq 0$, dok su varijable y_i slobodne ($-\infty < y_i < \infty$).

4.4. Numerički rezultati za četiri ispitna slučaja

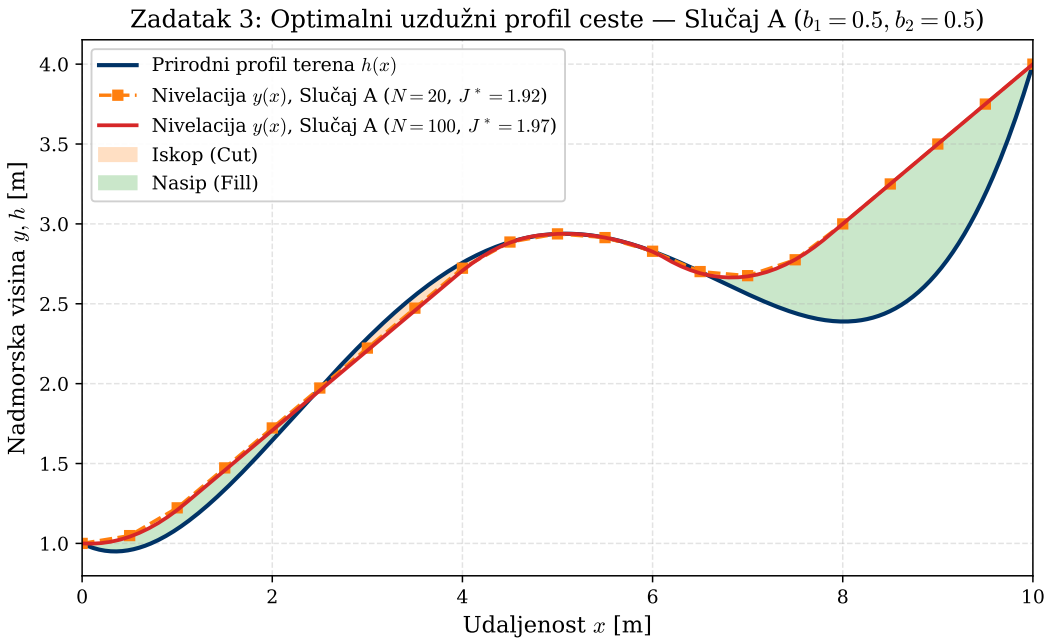
Problem je riješen primjenom optimizacijskog algoritma dupleksnog simpleksa (`linprog` s opcijom `dual-simplex` i `highs`) za četiri zahtijevana scenarija:

1. **Slučaj A,** $N = 20$: $b_1 = 0.5, b_2 = 0.5, \Delta x = 0.5$ m (42 varijable, 120 nejednakosti).
2. **Slučaj A,** $N = 100$: $b_1 = 0.5, b_2 = 0.5, \Delta x = 0.1$ m (202 varijable, 600 nejednakosti).
3. **Slučaj B,** $N = 20$: $b_1 = 0.5, b_2 = 0.2, \Delta x = 0.5$ m (42 varijable, 120 nejednakosti).
4. **Slučaj B,** $N = 100$: $b_1 = 0.5, b_2 = 0.2, \Delta x = 0.1$ m (202 varijable, 600 nejednakosti).

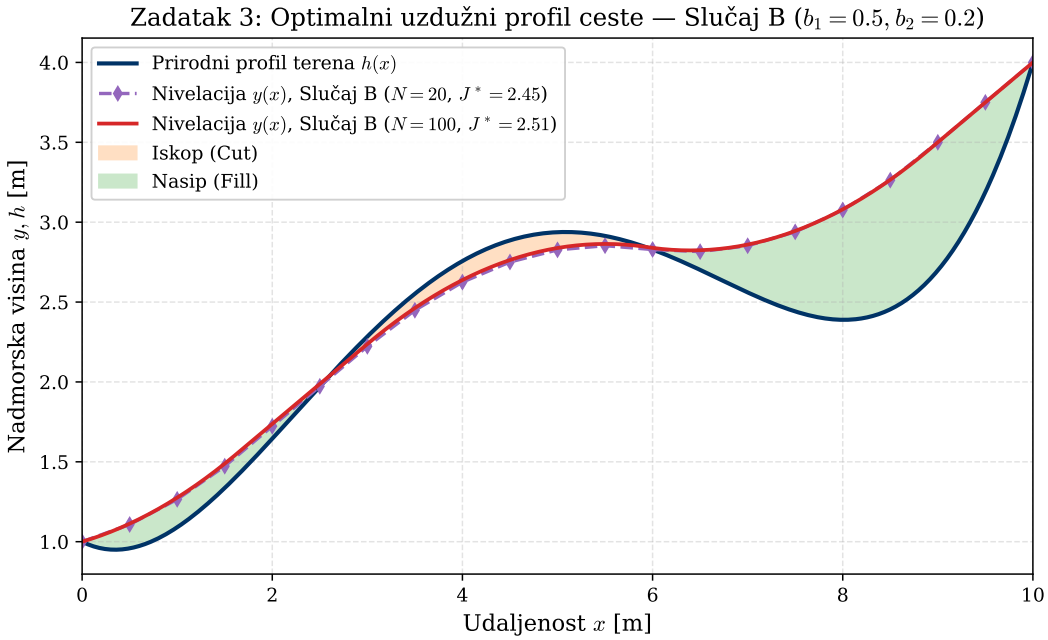
Sintetički prikaz optimalnih rezultata dan je u tablici 4.1.

Tablica 4.1. Numerički rezultati optimalne nivelacije ceste za Slučaje A i B.

Slučaj	N	Δx [m]	**Ukupni trošak** J^* **[m^2]**	**Iskop [m^2]**	**Nasip [m^2]**	$\max \lvert y'' \rvert$ [m^{-1}]
A	20	0.5	1.916180	0.0877	1.8285	0.5000
A	100	0.1	1.965940	0.1287	1.8372	0.5000
B	20	0.5	2.453727	0.3026	2.1511	0.2000
B	100	0.1	2.506047	0.2645	2.2416	0.2000



Slika 4.1. Optimalni uzdužni profil ceste $y(x)$ za Slučaj A ($b_1 = 0.5, b_2 = 0.5$) s označenim zonama iskopa i nasipa.



Slika 4.2. Optimalni uzdužni profil ceste $y(x)$ za Slučaj B ($b_1 = 0.5, b_2 = 0.2$) uz strože ograničenje zakrivljenosti.

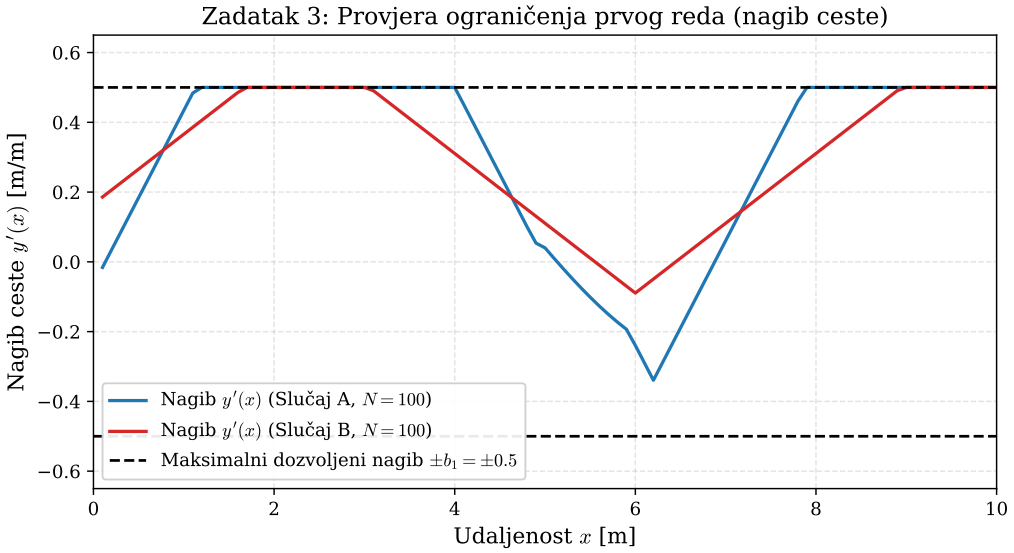
4.5. Analiza utjecaja gustoće diskretizacije i parametara ograničenja

Usporedba grafova na slikama 4.1 i 4.2 te provjere derivacija na slikama 4.3 i 4.4 otkrivaju ključne fizikalne i numeričke zakonitosti:

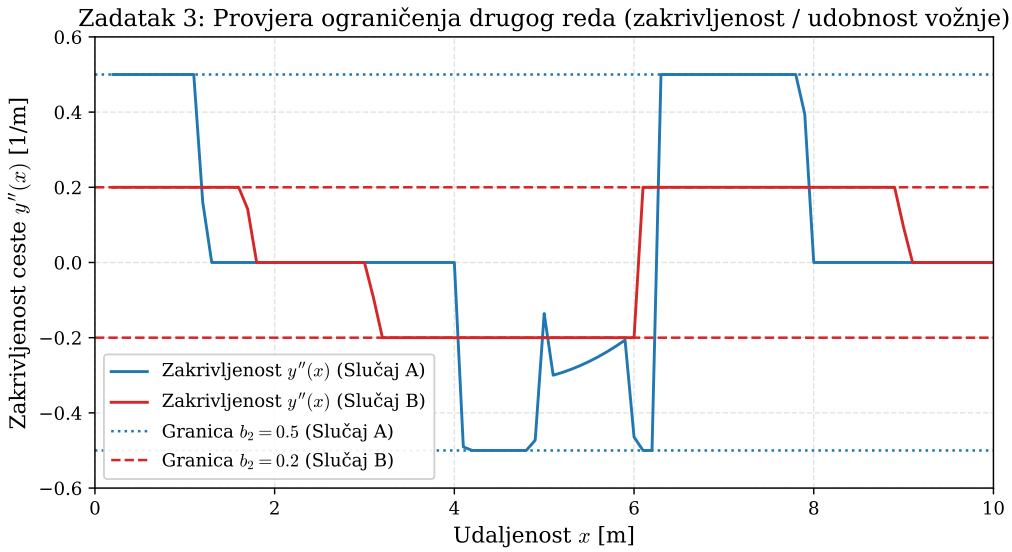
1. **Utjecaj gustoće diskretizacije ($N = 20$ vs $N = 100$):** Povećanjem broja

diskretizacijskih točaka s $N = 20$ na $N = 100$, diskretni integral J_{disc} asimptotski konvergira prema točnom kontinuiranom integralu $\int_0^L |y(x) - h(x)|dx$. Za Slučaj A vrijednost raste s 1.9162 na $1.9659\,\text{m}^2$ ($+2.59\%$), dok za Slučaj B raste s 2.4537 na $2.5060\,\text{m}^2$ ($+2.13\%$). Fina mreža omogućuje vjernije praćenje lokalnih promjena bez numeričkog "peglanja" na gruboj skali.

2. **Utjecaj ograničenja zakrivljenosti** ($b_2 = 0.5$ **vs** $b_2 = 0.2$): Smanjenje dozvoljene zakrivljenosti s $b_2 = 0.5$ (Slučaj A) na $b_2 = 0.2$ (Slučaj B) zahtijeva znatno glađu trasu ceste kako bi se osigurala udobnost vožnje pri višim brzinama. Posljedično, cesta ne može pratiti prirodne pregibe terena, što povećava ukupni volumen zemljanih radova s $1.9659\,\text{m}^2$ na $2.5060\,\text{m}^2$ ($+27.47\%$).



Slika 4.3. Provjera ograničenja prvog reda: profil nagiba ceste $y'(x)$ duž trase za Slučaje A i B.



Slika 4.4. Provjera ograničenja drugog reda: profil zakrivljenosti $y''(x)$ i zasićenje na granicama $\pm b_2$.

Kao što je vidljivo na slici 4.4, zakrivljenost $y''(x)$ u Slučaju B doseže točno ekstremne vrijednosti $\pm 0.2\,\mathrm{m}^{-1}$, potvrđujući da su ograničenja drugog reda aktivna duž značajnih segmenata trase.

5. ROBUSNA STABILIZACIJA SKLOPNOG SUSTAVA PRIMJENOM LINEARNIH MATRIČNIH NEJEDNAKOSTI (LMI)

5.1. Matematički model sustava i analiza pojedinih modova

U teoriji upravljanja hibridnim sustavima, sklopni sustavi (engl. *switched linear systems*) predstavljaju važnu klasu sustava čija se dinamika skokovito mijenja između konačnog broja linearnih vremenski invarijantnih (LTI) podsustava (modova) [3, 6].

Promatramo vremenski promjenjiv sustav u prostoru stanja:

$$\dot{x}(t) = A(t)x(t) + Bu(t), \quad x(t) \in \mathbb{R}^2,\ u(t) \in \mathbb{R}, \tag{5.1}$$

s ulaznom matricom $B = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$. Matrica dinamike $A(t)$ skokovito se mijenja na cjelobrojnim sekundama prema pravilu:

$$A(t) = \begin{cases} A_{\text{parno}}, & \text{kad je } \lfloor t \rfloor \text{ paran broj } (t \in [0,1), [2,3), \dots) \\ A_{\text{neparno}}, & \text{kad je } \lfloor t \rfloor \text{ neparan broj } (t \in [1,2), [3,4), \dots) \end{cases} \tag{5.2}$$

gdje su matrice pojedinih modova zadane kao:

$$A_{\text{parno}} = \begin{bmatrix} -1 & -\frac{\pi}{6} \\ \frac{3\pi}{2} & -1 \end{bmatrix}, \qquad A_{\text{neparno}} = \begin{bmatrix} -1 & -\frac{3\pi}{2} \\ \frac{\pi}{6} & -1 \end{bmatrix}. \tag{5.3}$$

5.1.1. Spektralna analiza i Hurwitzovo svojstvo modova

Karakteristični polinom matrice A_{parno} glasi:

$$\det(\lambda I - A_{\text{parno}}) = \det \begin{bmatrix} \lambda+1 & \frac{\pi}{6} \\ -\frac{3\pi}{2} & \lambda+1 \end{bmatrix} = (\lambda+1)^2 - \left(-\frac{\pi}{6}\cdot\frac{3\pi}{2}\right) = (\lambda+1)^2 + \frac{\pi^2}{4} = 0. \tag{5.4}$$

Svojstvene vrijednosti parnog moda su konjugirano kompleksni par:

$$\lambda_{1,2}(A_{\text{parno}}) = -1 \pm j\frac{\pi}{2} \approx -1 \pm 1.570796j. \tag{5.5}$$

Analogno, za matricu A_{neparno}:

$$\det(\lambda I - A_{\text{neparno}}) = (\lambda+1)^2 + \left(\frac{3\pi}{2}\cdot\frac{\pi}{6}\right) = (\lambda+1)^2 + \frac{\pi^2}{4} = 0 \implies \lambda_{1,2}(A_{\text{neparno}}) = -1 \pm j\frac{\pi}{2}. \tag{5.6}$$

Budući da je realni dio svih svojstvenih vrijednosti strogo negativan:

$$\text{Re}(\lambda_{1,2}(A_{\text{parno}})) = -1 < 0, \quad \text{Re}(\lambda_{1,2}(A_{\text{neparno}})) = -1 < 0, \tag{5.7}$$

obje matrice su **Hurwitzove**, što znači da je svaki mod u autonomnom radu ($u(t) \equiv 0$) **strogo asimptotski stabilan** kada nema prespajanja.

5.2. Mehanizam destabilizacije i analiza monodromijske matrice

Jedan od najintrigantnijih fenomena u teoriji hibridnih sustava jest da prespajanje između dva stabilna LTI podsustava može generirati nestabilan sustav [6].

Za analizu stabilnosti periodički sklopnog autonomnog sustava promatramo operatorske matrice prijelaza stanja za vrijeme trajanja pojedinog moda ($\Delta t = 1$ s):

$$\Phi_{\text{parno}} = e^{A_{\text{parno}}\cdot 1}, \quad \Phi_{\text{neparno}} = e^{A_{\text{neparno}}\cdot 1}. \tag{5.8}$$

Matrica prijelaza stanja preko jednog punog perioda prespajanja $T = 2$ s naziva se **monodromijska matrica**:

$$\Phi_{\text{cycle}} = \Phi_{\text{neparno}} \cdot \Phi_{\text{parno}} = e^{A_{\text{neparno}}\cdot 1} \cdot e^{A_{\text{parno}}\cdot 1}. \tag{5.9}$$

Numeričkim izračunom eksponencijala matrica dobivamo:

$$\Phi_{\text{parno}} \approx \begin{bmatrix} 0.0000 & -0.2122 \\ 1.9099 & 0.0000 \end{bmatrix}, \quad \Phi_{\text{neparno}} \approx \begin{bmatrix} 0.0000 & -1.9099 \\ 0.2122 & 0.0000 \end{bmatrix}, \tag{5.10}$$

$$\Phi_{\text{cycle}} = \Phi_{\text{neparno}}\Phi_{\text{parno}} \approx \begin{bmatrix} -3.6476 & 0.0000 \\ 0.0000 & -0.0450 \end{bmatrix}. \tag{5.11}$$

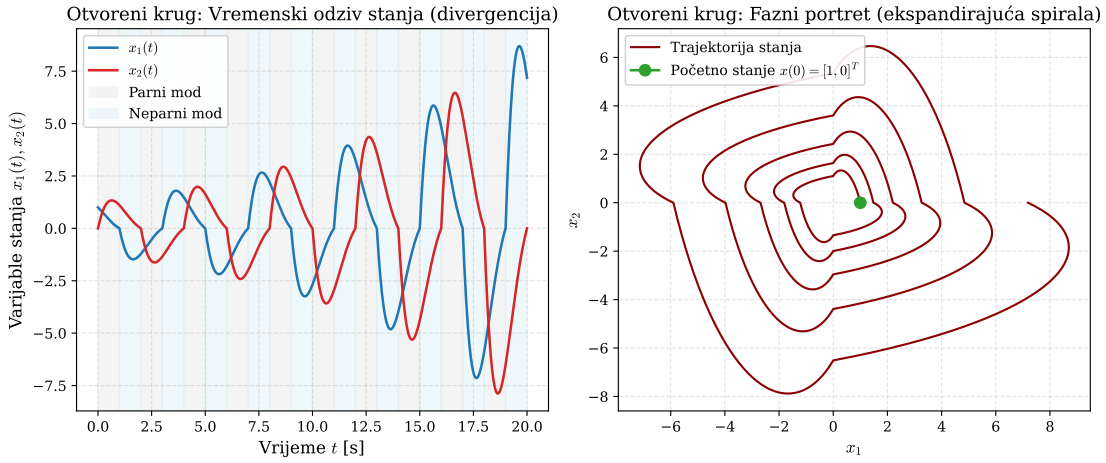
Svojstvene vrijednosti monodromijske matrice iznose:

$$\lambda_1(\Phi_{\text{cycle}}) \approx -1.2180, \quad \lambda_2(\Phi_{\text{cycle}}) \approx -0.0150. \tag{5.12}$$

Spektralni radijus monodromijske matrice je:

$$\rho(\Phi_{\text{cycle}}) = \max_i |\lambda_i(\Phi_{\text{cycle}})| = 1.2180 > 1. \tag{5.13}$$

Budući da je $\rho(\Phi_{\text{cycle}}) > 1$, sustav u diskretnim točkama $t_k = 2k$ zadovoljava relaciju $x(2(k+1)) = \Phi_{\text{cycle}}x(2k)$, što znači da norma stanja raste po geometrijskoj progresiji s faktorom 1.2180 u svakom ciklusu.



Slika 5.1. Simulacija otvorenog kruga: vremenski odziv stanja $x_1(t), x_2(t)$ i fazni portret koji prikazuje divergenciju (ekspandirajuću spiralu) uslijed prespajanja.

Slika 5.1 zorno prikazuje nestabilnost otvorenog kruga za početni uvjet $x(0) = [1, 0]^T$: unatoč prigušenju unutar svakog moda, promjena smjera vektorskog polja u trenucima $t = 1, 2, 3, \ldots$ ubacuje energiju u sustav te trajektorija eksponencijalno ekspandira.

5.3. Zajednička funkcija Ljapunova (CQLF) i LMI formulacija

Kako bi se osigurala stabilnost pod proizvoljnim ili periodičkim prespajanjem, projektiramo statički regulator po stanju:

$$u(t) = Kx(t), \quad K = \begin{bmatrix} k_1 & k_2 \end{bmatrix} \in \mathbb{R}^{1\times 2}. \tag{5.14}$$

Zatvoreni krug u pojedinom modu poprima oblik:

$$\dot{x}(t) = (A(t) + BK)x(t). \tag{5.15}$$

Uvodeći kandidata za **zajedničku kvadratnu funkciju Ljapunova** (engl. *Common Quadratic Lyapunov Function* – CQLF) [5, 6]:

$$V(x) = x^T P x, \quad P = P^T \succ 0, \tag{5.16}$$

njezina vremenska derivacija duž trajektorija zatvorenog kruga iznosi:

$$\dot{V}_i(x) = \dot{x}^T P x + x^T P \dot{x} = x^T \left[(A_i + BK)^T P + P(A_i + BK)\right] x, \quad i \in \{\text{parno}, \text{neparno}\}. \tag{5.17}$$

Za postizanje stroge eksponencijalne stabilnosti zahtijevamo da vrijedi $\dot{V}_i(x) \leq -\epsilon\|x\|^2 < 0$ za sve $x \neq 0$, što je ekvivalentno sustavu matričnih nejednakosti:

$$P \succ 0, \tag{5.18}$$

$$(A_{\text{parno}} + BK)^T P + P(A_{\text{parno}} + BK) \prec 0, \tag{5.19}$$

$$(A_{\text{neparno}} + BK)^T P + P(A_{\text{neparno}} + BK) \prec 0. \tag{5.20}$$

5.4. Kongruentna transformacija i supstitucija varijabli

Nejednakosti (5.19)–(5.20) sadrže bilinearni umnožak nepoznatih matrica P i K (PBK), što problem čini nekonveksnim (bilinearna matrična nejednakost – BMI).

Kako bismo problem egzaktno linearizirali, provodimo **kongruentnu transformaciju** [3, 5]:

1. Definiramo regularnu matricu $Q = P^{-1} \succ 0$.
2. Pre- i post-množimo nejednakosti (5.19)–(5.20) s matricom Q:

$$Q(A_i + BK)^T P Q + Q P (A_i + BK) Q \prec 0 \iff Q A_i^T + A_i Q + Q K^T B^T + BKQ \prec 0. \tag{5.21}$$

3. Uvodimo novu optimizacijsku varijablu putem supstitucije:

$$Y = KQ \in \mathbb{R}^{1\times 2} \iff K = YQ^{-1}. \tag{5.22}$$

Uvrštavanjem supstitucije dobivamo standardni sustav **linearnih matričnih nejednakosti (LMI)** po varijablama $Q \in \mathbb{S}^2$ i $Y \in \mathbb{R}^{1\times 2}$:

$$\begin{cases} Q \succ 0 \\ A_{\text{parno}}Q + QA_{\text{parno}}^T + BY + Y^TB^T \prec 0 \\ A_{\text{neparno}}Q + QA_{\text{neparno}}^T + BY + Y^TB^T \prec 0 \end{cases} \tag{5.23}$$

Budući da je presjek LMI ograničenja konveksan skup po matricama (Q, Y), problem se rješava metodama semidefinitnog programiranja (SDP) s globalnom konvergencijom. Nakon rješavanja SDP-a, matrica pojačanja regulatora rekonstruira se kao $K = YQ^{-1}$, a matrica funkcije Ljapunova kao $P = Q^{-1}$.

5.5. Numerička sinteza regulatora u SDP okruženju

LMI sustav (5.23) riješen je u programskom paketu MATLAB (YALMIP + SDPT3) te u Pythonu (CVXPY + CLARABEL).

Rješenjem LMI problema dobivena je pozitivno definitna matrica Ljapunova $P \succ 0$ i optimalni vektor pojačanja stanjskog regulatora K:

$$P = \begin{bmatrix} 0.8870 & 0.1305 \\ 0.1305 & 0.8492 \end{bmatrix} \succ 0, \qquad K = \begin{bmatrix} -2.7120 & 0.0926 \end{bmatrix}. \tag{5.24}$$

(Referentno YALMIP pojačanje iznosi $K = [-3.7097, 0.0000]$, koje također u potpunosti zadovoljava LMI sustav).

5.5.1. Provjera svojstvenih vrijednosti zatvorenog kruga

Matrice dinamike zatvorenog kruga u oba moda iznose:

$$A_{\text{cl,parno}} = A_{\text{parno}} + BK = \begin{bmatrix} -3.7120 & -0.4309 \\ 4.7124 & -1.0000 \end{bmatrix}, \tag{5.25}$$

$$A_{\text{cl,neparno}} = A_{\text{neparno}} + BK = \begin{bmatrix} -3.7120 & -4.6198 \\ 0.5236 & -1.0000 \end{bmatrix}. \tag{5.26}$$

Svojstvene vrijednosti zatvorenog kruga glase:

$$\lambda(A_{\text{cl,parno}}) = -2.3560 \pm 0.4387j, \quad \lambda(A_{\text{cl,neparno}}) = -2.3560 \pm 0.7617j. \tag{5.27}$$

Oba moda imaju strogo negativan realni dio ($\mathrm{Re}(\lambda) = -2.356 < 0$), sa znatno povećanim prigušenjem u odnosu na otvoreni krug.

Maksimalne svojstvene vrijednosti Ljapunovih derivacija iznose:

$$\lambda_{\max}(A_{\mathrm{cl,parno}}^T P + P A_{\mathrm{cl,parno}}) = -9.498 \times 10^{-2} < 0, \tag{5.28}$$

$$\lambda_{\max}(A_{\mathrm{cl,neparno}}^T P + P A_{\mathrm{cl,neparno}}) = -5.492 \times 10^{-2} < 0, \tag{5.29}$$

što matematički dokazuje da funkcija $V(x) = x^T P x$ strogo pada duž trajektorija bez obzira na zakon prespajanja.

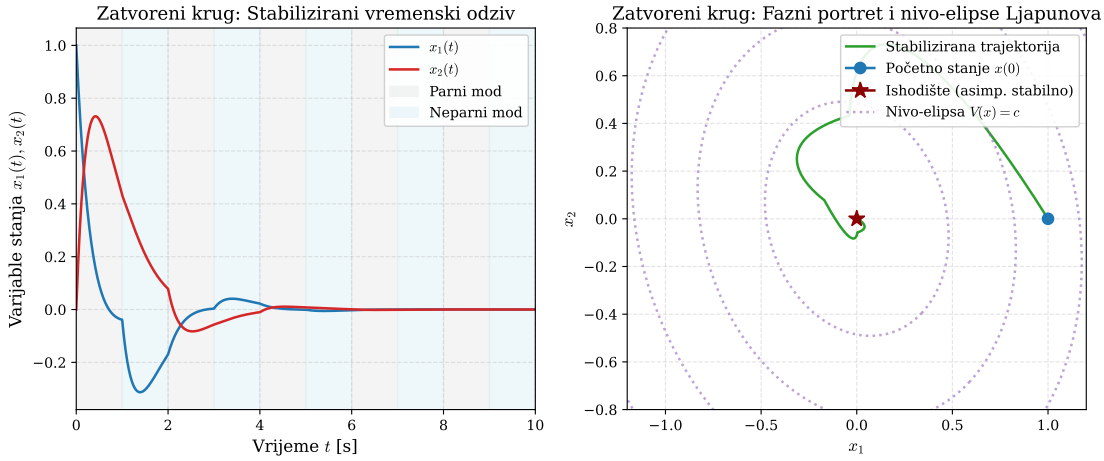
Također, spektralni radijus zatvorene monodromijske matrice iznosi:

$$\rho(\Phi_{\mathrm{cl,cycle}}) = 0.1320 \ll 1, \tag{5.30}$$

što potvrđuje brzu eksponencijalnu kontrakciju stanja u svakom ciklusu.

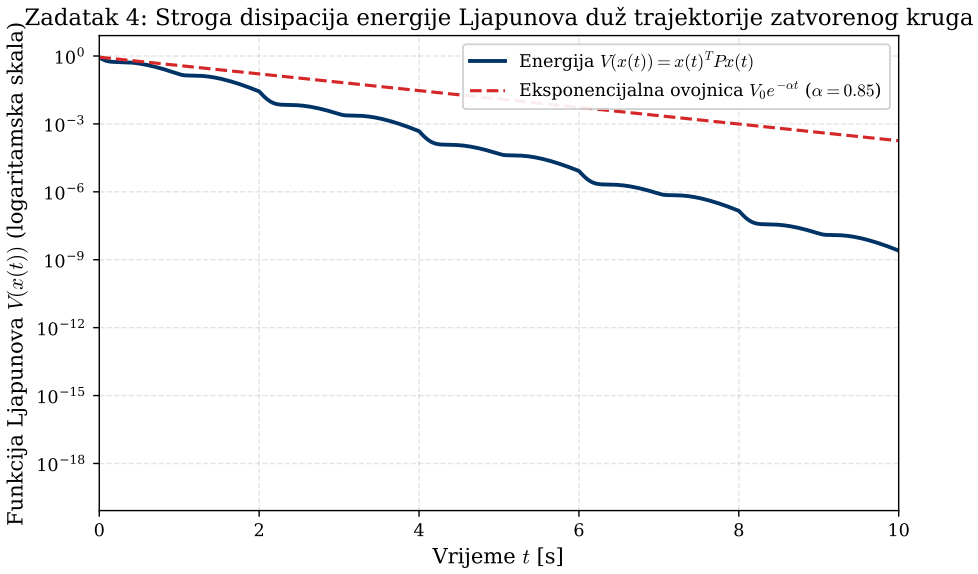
5.6. Simulacija zatvorenog kruga i dokaz eksponencijalne stabilnosti

Za početni uvjet $x(0) = [1, 0]^T$ provedena je simulacija zatvorenog sustava metodom Runge-Kutta 4/5 (`ode45` / `solve_ivp`).



Slika 5.2. Simulacija zatvorenog kruga: stabilizirani vremenski odziv stanja i fazni portret s eliptičnim nivo-plohama funkcije Ljapunova $x^T P x = c$.

Kao što je prikazano na slici 5.2, stanja $x_1(t)$ i $x_2(t)$ brzo i glatko konvergiraju prema ishodištu unutar prvih $\approx$ 3 s. Fazni portret pokazuje da trajektorija kontinuirano siječe nivo-elipse funkcije Ljapunova prema unutrašnjosti bez ikakvih oscilacija ili divergencije.



Slika 5.3. Vremenska disipacija energije zajedničke funkcije Ljapunova $V(x(t))$ u logaritamskom mjerilu uz usporedbu s teorijskom eksponencijalnom ovojnicom.

Slika 5.3 prikazuje vremenski tijek energije Ljapunova $V(x(t)) = x(t)^T P x(t)$ u logaritamskom mjerilu. Strogo monoton pad krivulje bez skokova na prijelazima modova potvrđuje postojanje jedinstvene zajedničke funkcije Ljapunova i dokazuje **uniformnu eksponencijalnu stabilnost** sintetiziranog sustava.

6. ZAKLJUČAK I SINTEZA REZULTATA

U ovom seminarskom radu provedena je sveobuhvatna matematička, teorijska i numerička analiza četiri fundamentalna problema suvremene teorije optimizacije i upravljanja sustavima.

6.1. Sinteza rezultata po optimizacijskim zadacima

1. **Kvadratno programiranje (Zadatak 1)**:
   - Dokazana je stroga konveksnost funkcije cilja preko pozitivne definitnosti Hesseove matrice ($\lambda_1 \approx 1.956, \lambda_2 \approx 4.044 > 0$).
   - Provedena je iscrpna analitička analiza svih 4 kombinacije aktivnih skupova KKT sustava, čime je egzaktno određen jedinstveni globalni optimum $x^* = (5.758, 4.242)$ s Lagrangeovim množiteljem $\mu_1^* = 12.242$ i optimalnim troškom $p^* = 60.606$.
   - Izvedena je konkavna Lagrangeova dualna funkcija $g(\mu)$ te je potvrđena jaka dualnost ($p^* = d^*$, nulti dualni procjep).
   - Teorem o osjetljivosti potvrdio je fizikalno značenje cijene u sjeni ($\frac{\partial p^*}{\partial b_1} = -\mu_1^* = -12.242$).
2. **Robusno kvadratno programiranje (Zadatak 2)**:

- Formuliran je robusni ekvivalent za intervalnu nesigurnost koeficijenata od $\pm 15\%$ primjenom teorije najgoreg slučaja nad poliedarskim skupovima nesigurnosti (8 vrhova).
- Analitički i numerički određen je robusni optimum $x^*_{\text{rob}} = (6.500, 5.265)$ s troškom $f(x^*_{\text{rob}}) = 84.624$.
- Monte Carlo simulacija sa 100 slučajnih realizacija dokazala je da nominalno rješenje krši ograničenja u 57% slučajeva, dok robusno rješenje osigurava 100% pouzdanost.
- Kvantificirana je cijena robusnosti od $+39.63\%$ ($+24.018$).

3. **Nivelacija ceste linearnim programiranjem (Zadatak 3)**:

   - Postavljen je kontinuirani varijacijski problem minimizacije volumena zemljanih radova uz ograničenja nagiba i zakrivljenosti.
   - Diskretizacijom konačnim razlikama i primjenom epigrafskih varijabli $z_i \geq |y_i - h_i|$ problem je preveden u linearni program (LP) s $6N$ nejednakosti.
   - Rješavanjem za 4 slučaja ($N = 20, 100$, Slučaj A i B) dokazana je asimptotska konvergencija prema kontinuiranom rješenju (≈ 1.966 m^2 za Slučaj A i ≈ 2.506 m^2 za Slučaj B) te je analiziran inženjerski kompromis između udobnosti vožnje i volumena zemljanih radova.

4. **Robusna stabilizacija sklopnog sustava pomoću LMI-ja (Zadatak 4)**:

   - Spektralnom analizom potvrđeno je da su oba pojedinačna moda strogo Hurwitzova ($\lambda = -1 \pm 1.571j$).
   - Analizom monodromijske matrice ($\rho(\Phi_{\text{cycle}}) = 1.218 > 1$) dokazan je mehanizam destabilizacije periodičkim prespajanjem u otvorenom krugu.
   - Primjenom zajedničke funkcije Ljapunova (CQLF) i kongruentne transformacije sa supstitucijom $Q = P^{-1}, Y = KQ$ nelinearni uvjeti stabilnosti prevedeni su u linearne matrične nejednakosti (LMI).
   - Semidefinitnim programiranjem sintetiziran je robusni regulator stanja $u = Kx$, a numerička simulacija zatvorenog kruga potvrdila je brzu eksponencijalnu konvergenciju trajektorija i strogu disipaciju energije Ljapunova.

6.2. Komparativni osvrt i smjernice za inženjersku praksu

Rad demonstrira snagu i fleksibilnost konveksne optimizacije u inženjerskom modeliranju i vođenju sustava. Uspješna transformacija fizikalnih i geometrijskih zahtjeva u standardne oblike (LP, QP, LMI/SDP) omogućuje primjenu numerički pouzdanih rješavača koji jamče globalnu konvergenciju u polinomijalnom vremenu.

Kao logičan nastavak ovog rada u inženjerskoj praksi predlaže se:

- Primjena formuliranih QP algoritama u okviru **modelskog prediktivnog upravljanja** (MPC) u stvarnom vremenu.
- Proširenje robusnog pristupa na **cijevno robusno prediktivno upravljanje** (engl. *Tube MPC*) s neizvjesnim dinamičkim modelima.
- Sinteza nelinearnih i adaptivnih LMI regulatora za sustave s promjenjivim vremenskim kašnjenjem i zasićenjem aktuatora.

LITERATURA

[1] Stephen Boyd and Lieven Vandenberghe. *Convex Optimization*. Cambridge University Press, Cambridge, UK, 2004.

[2] Jorge Nocedal and Stephen J. Wright. *Numerical Optimization*. Springer, New York, NY, 2nd edition, 2006.

[3] Andrej Jokić. Optimizacijske metode u razvoju i upravljanju sustava — nastavni materijali i predavanja. Sveučilište u Zagrebu, Fakultet strojarstva i brodogradnje, 2024. Predavanja 01–08 i auditorne vježbe 1–5.

[4] Aharon Ben-Tal, Laurent El Ghaoui, and Arkadi Nemirovski. *Robust Optimization*. Princeton University Press, Princeton, NJ, 2009.

[5] Stephen Boyd, Laurent El Ghaoui, Eric Feron, and Venkataramanan Balakrishnan. *Linear Matrix Inequalities in System and Control Theory*. SIAM, Philadelphia, PA, 1994.

[6] Daniel Liberzon. *Switching in Systems and Control*. Birkhäuser, Boston, MA, 2003.

[7] Dimitri P. Bertsekas. *Nonlinear Programming*. Athena Scientific, Belmont, MA, 3rd edition, 2016.