SVEUČILIŠTE U ZAGREBU
FAKULTET STROJARSTVA I BRODOGRADNJE

SEMINARSKI RAD

OPTIMIZACIJSKE METODE U RAZVOJU I UPRAVLJANJU SUSTAVA

Profesor: Student:

Prof. dr. sc. Andrej Jokić **Krešimir Hartl**

Zagreb, 2026.

Student: KREŠIMIR HARTL	Mat. broj:

Zadatak 1. (QP, konveksnost, KKT, dualnost) Zadan je optimizacijski problem

$$\min_x \quad x_1^2 + 2x_2^2 - 0.3x_1x_2 + 2x_1 - 3x_2 \tag{1a}$$

$$\text{uz ograničenja} \quad a_{11}x_1 + a_{12}x_2 \leq -10, \tag{1b}$$

$$a_{21}x_1 + a_{22}x_2 \leq 3, \tag{1c}$$

gdje su numeričke vrijednosti koeficijenata $a_{11} = -1$, $a_{12} = -1$, $a_{21} = 1$, $a_{22} = -1$.

a) Je li ovo konveksan optimizacijski problem? Obrazložiti odgovor.

b) Postavite KKT uvjete optimalnosti i riješite ih (odredite vrijednosti projektnih varijabli i Lagrangeovih množitelja koji zadovoljavaju te uvjete).

c) Nacrtajte dozvoljeni skup, nivo krivulje funkcije cilja te izračunajte i skicirati gradijente ograničenja i funkcije cilja u točki koja zadovoljava KKT uvjete.

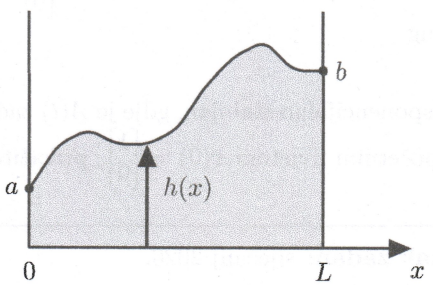
d) Riješite problem u MATLABu (quadprog i/ili yalmip) - odredite primarne i dualne varijable u optimumu te ih usporedite s rezultatima (Lagrangeovim množiteljima) iz (b).

e) Postavite i riješite Lagrangeov dualan problem (koristite MATLAB za numeričko rješavanje dualnog problema). Usporedite vrijednost izračunatih dualnih varijabli s onima dobivenim pod (d) i (b).

f) Što možete reći o osjetljivosti optimalne vrijednosti ($p^\star$ = opt. vrijednost primarnog problema) na perturbacije u ograničenjima (na perturbacije koeficijenata b_1 i b_2)?

Zadatak 2. (Robustan QP) Za optimizacijski problem iz Zadatka 1. pretpostavimo da su koeficijenti a_{ij}, $i = 1, 2$, $j = 1, 2$ nesigurni u sljedećem smislu. Jedino što znamo je da se njihove stvarne vrijednosti nalaze u intervalu od $\pm 15\%$ od numeričkih vrijednosti zadanih u Zadatku 1: stvarna vrijednost $a_{ij,\text{stvarno}}$ se nalazi u intervalu od $0.85a_{ij}$ do $1.15a_{ij}$, gdje je a_{ij} numerička vrijednost iz Zadatka 1. Riješite ovako zadan robustan optimizacijski problem. Nacrtajte dozvoljen skup za niz slučajno izabranih koeficijenta iz dozvoljenih intervala te na istoj slici označite gdje se nalazi točka optimuma.

Zadatak 3. (Formulacija opt. problema; opt. aproksimacija s ograničenjima) Potrebno je izgraditi cestu na neravnom terenu. Trošak izrade ceste proporcionalan je količini materijala (zemlje) kojeg treba oduzeti (otkopati) ili dodati da bi se dobio donekle "poravnan" teren prikladan za izgradnju ceste.
Neka je L sveukupna duljina ceste (točnije projekcija duljine ceste na horizontalnu os x), a $h(x)$ je poznata visina terena u ovisnosti o koordinati $x \in [0, L]$ - vidjeti sliku za ilustraciju. Potrebno je odrediti visinu ceste $y(x)$ za $x \in [0, L]$ koja rezultira minimalnim troškovima izrade, s time da je nužno poštovati sljedeća ograničenja:



- nagib ceste ne smije biti veći od b_1;
- za ugodnu vožnju brzina promjene nagiba ceste ne smije biti veća od b_2;
- rubni uvjeti $y(0) = a$ i $y(L) = b$ moraju biti zadovoljeni.

Zadano je:

$$L = 10, \tag{2a}$$

$$h(x) = 0.0053x^4 - 0.095x^3 + 0.48x^2 - 0.3x + 1, \tag{2b}$$

$$a = h(0) = 1, \quad b = h(L) = 4. \tag{2c}$$

$$\text{slučaj A: } b_1 = 0.5,\ b_2 = 0.5 \tag{2d}$$

$$\text{slučaj B: } b_1 = 0.5,\ b_2 = 0.2 \tag{2e}$$

Upute: Koordinate x na intervalu $[0, L]$ diskretizirajte s $N+1$ točaka $\{x_0, x_1, \ldots, x_N\}$, odnosno ovaj interval podijelite na N podintervala od kojih je svaki duljine $\Delta h = L/N$ (uočite $x_0 = 0, x_N = L$). Tada visinu ceste računajte samo u točkama diskretizacije $\{y_0 = y(x_0), y_1 = y(x_1), \ldots, y_N = y(x_L)\}$. Nagib ceste (derivaciju) aproksimirajte prvom podijeljenom razlikom: $y'(x_i) \approx \nabla y_i := \frac{1}{\Delta x}(y_i - y_{i-1})$, a brzinu promjene nagiba (druga derivacija) s $y''(x_i) \approx \nabla^2 y_i := \frac{1}{\Delta x}(\nabla y_i - \nabla y_{i-1})$.
Zadatci:

- Formulirajte problem kao optimizacijski problem. Kojoj klasi optimizacijskih problema pripada ovaj problem?
- Riješite problem za 4 različita slučaja: *i*) za slučaj A (parametri zadani s (2d)) te s $N = 20$; *ii*) za slučaj A s $N = 100$; *iii*) za slučaj B (parametri zadani s (2e)) te s $N = 20$; *iv*) za slučaj B s $N = 100$.

Zadatak 4. (Robusna stabilizacija) Promotrimo sljedeći vremenski promjenjiv sustav

$$\dot{x}(t) = A(t)x(t) + Bu(t) \tag{3}$$

gdje je $x(t)$ varijabla stanja, a $u(t)$ je ulazni (upravljački) signal. Matrica $A(t)$ i vremenski promjenjiva (t označava vrijeme) i to prema sljedećem pravilu:

$$A(t) = \begin{cases} A_{\text{parno}} & \text{kad je } \lfloor t \rfloor \text{ paran broj} \\ A_{\text{neparno}} & \text{kad je } \lfloor t \rfloor \text{ neparan broj} \end{cases} \tag{4}$$

gdje $\lfloor t \rfloor$ označava najveći cijeli broj koji je manji ili jednak t (zaokruživanja broja t na prvi manji cijeli broj). Imamo

$$A_{\text{parno}} = \begin{bmatrix} -1 & -\frac{1}{6}\pi \\ \frac{3}{2}\pi & -1 \end{bmatrix}, \qquad A_{\text{neparno}} = \begin{bmatrix} -1 & -\frac{3}{2}\pi \\ \frac{1}{6}\pi & -1 \end{bmatrix}. \tag{5}$$

Ovdje se u biti radi o hibridnom sustavu sa "skokovitom" promjenom dinamike (*switching*) u diskretnim vremenskim trenutcima. Između svaka dva trenutka u kojima se odvija ova skokovita promjena, sustav je linearan vremenski invarijantan. Kažemo da ovaj sustav ima dva dinamička moda.

a) Jesu li matrice A_{parno} i A_{neparno} stabilne matrice (Hurwitzove matrice)? Odnosno, jesu li oba dinamička moda stabilna? (Napomena: ovo možete provjeriti izračunom svojstvenih vrijednosti ovih matrica).

b) Simulirajte vremenski promjenjiv sustav (3) s početnim uvjetom $x(0) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, prikažite $x(t)$ (graf kako se varijable stanja mijenjaju s vremenom) i prikažite trajektoriju sustava u prostoru stanja. Je li ovaj sustav stabilan?

c) U sustavu (3), neka je matrica $B = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$. Dizajnirajte statički regulator $u(t) = Kx(t)$ takav da je zatvoreni krug

$$\dot{x}(t) = (A(t) + BK)x(t) \tag{6}$$

eksponencijalno stabilan, gdje je $A(t)$ zadana s (4). Simulirajte ovaj vremenski promjenjiv zatvorni sustav s početnim uvjetom $x(0) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, prikažite $x(t)$ i prikažite trajektoriju sustava u prostoru stanja.

Zadatak zadan: siječanj 2026. **Rok predaje rada:** lipanj 2027.

Zadao, mentor: **Ocjena:**

Prof.dr.sc. Andrej Jokić

SADRŽAJ

1 Uvod **1**

2 Zadatak 1: kvadratni program, KKT uvjeti, dualnost i osjetljivost **1**
2.1 Formulacija problema 1
2.2 (a) Je li problem konveksan? 2
2.3 (b) KKT uvjeti i njihovo rješavanje 2
2.4 (c) Grafički prikaz 4
2.5 (d) Numeričko rješenje u MATLAB-u 5
2.6 (e) Lagrangeov dualni problem 6
2.7 (f) Osjetljivost optimalne vrijednosti 7

3 Zadatak 2: robusni kvadratni program **8**
3.1 Skup nesigurnosti i robusna formulacija 8
3.2 Ekvivalentan problem s konačno mnogo nejednakosti 8
3.3 Analitičko rješenje i provjera KKT uvjeta 9
3.4 Rješenje u MATLAB-u 10
3.5 Slučajne realizacije i usporedba s nominalnim rješenjem 11

4 Zadatak 3: nivelacija ceste kao problem linearnog programiranja **13**
4.1 (a) Formulacija problema i klasa kojoj pripada 13
4.2 Diskretizacija konačnim razlikama 13
4.3 Prijelaz na standardni oblik linearnog programa 14
4.4 (b) Rješenja za četiri zadana slučaja 15
4.5 Analiza utjecaja parametara 17

5 Zadatak 4: robusna stabilizacija sklopnog sustava **18**
5.1 Model sustava 18
5.2 (a) Jesu li matrice modova Hurwitzove? 19
5.3 (b) Simulacija sklopnog sustava 19
5.4 (c) Sinteza regulatora pomoću linearnih matričnih nejednakosti 21
5.4.1 Provjera dobivenog rješenja 22
5.4.2 Simulacija zatvorenog kruga 23

6 Zaključak **23**

1. UVOD

U ovom seminarskom radu rješavaju se četiri zadatka iz kolegija *Optimizacijske metode u razvoju i upravljanju sustava*. Redom su to: kvadratni program s dva ograničenja nejednakosti, njegova robusna inačica uz intervalnu nesigurnost koeficijenata, formulacija nivelacije uzdužnog profila ceste kao linearnog programa te sinteza regulatora po varijablama stanja za sklopni linearni sustav pomoću linearnih matričnih nejednakosti.

Zajednička nit svih zadataka je konveksnost: nakon što se problem zapiše u standardnom obliku (LP, QP ili SDP), lokalni optimum je ujedno globalan, a KKT uvjeti odnosno linearne matrične nejednakosti daju provjerljiv certifikat optimalnosti ili stabilnosti [1, 2].

Svi proračuni provedeni su u MATLAB-u (verzija R2025b): `quadprog` za kvadratne programe u zadacima 1 i 2, `linprog` za linearni program u zadatku 3 te YALMIP sa rješavačem SDPT3 za semidefinitni program u zadatku 4. Skripte se nalaze u prilogu; svaka brojka i svaka slika u radu proizlazi iz jednog pokretanja tih skripti.

Poglavlja slijede numeraciju zadataka:

- **Poglavlje 2** — Zadatak 1: konveksnost, KKT uvjeti, `quadprog`, Lagrangeov dualni problem i osjetljivost optimalne vrijednosti.
- **Poglavlje 3** — Zadatak 2: robusni ekvivalent uz nesigurnost koeficijenata od $\pm 15\%$ i usporedba s nominalnim rješenjem.
- **Poglavlje 4** — Zadatak 3: diskretizacija konačnim razlikama, LP formulacija i rješenja za četiri zadana slučaja.
- **Poglavlje 5** — Zadatak 4: stabilnost pojedinih modova, simulacija sklopnog sustava i LMI sinteza stabilizirajućeg regulatora.

2. ZADATAK 1: KVADRATNI PROGRAM, KKT UVJETI, DUALNOST I OSJETLJIVOST

2.1. Formulacija problema

Zadan je problem

$$\min_{x \in \mathbb{R}^2} \quad f(x) = x_1^2 + 2x_2^2 - 0.3x_1x_2 + 2x_1 - 3x_2 \tag{2.1}$$

uz ograničenja

$$g_1(x) = a_{11}x_1 + a_{12}x_2 + 10 \leq 0, \tag{2.2}$$

$$g_2(x) = a_{21}x_1 + a_{22}x_2 - 3 \leq 0, \tag{2.3}$$

gdje je $a_{11} = -1$, $a_{12} = -1$, $a_{21} = 1$, $a_{22} = -1$, odnosno

$$g_1(x) = -x_1 - x_2 + 10 \leq 0, \qquad g_2(x) = x_1 - x_2 - 3 \leq 0. \tag{2.4}$$

Funkcija cilja zapisuje se u obliku $f(x) = \frac{1}{2}x^{\mathsf{T}}Qx + c^{\mathsf{T}}x$, a ograničenja u obliku $Gx - h \leq 0$:

$$Q = \begin{bmatrix} 2 & -0.3 \\ -0.3 & 4 \end{bmatrix}, \quad c = \begin{bmatrix} 2 \\ -3 \end{bmatrix}, \quad G = \begin{bmatrix} -1 & -1 \\ 1 & -1 \end{bmatrix}, \quad h = \begin{bmatrix} -10 \\ 3 \end{bmatrix}. \tag{2.5}$$

2.2. (a) Je li problem konveksan?

Hesseova matrica funkcije cilja jednaka je matrici Q iz (2.5). Njezine svojstvene vrijednosti slijede iz karakteristične jednadžbe

$$\det(\lambda I - Q) = (\lambda - 2)(\lambda - 4) - 0.09 = \lambda^2 - 6\lambda + 7.91 = 0, \tag{2.6}$$

$$\lambda_{1,2} = \frac{6 \pm \sqrt{4.36}}{2} \implies \lambda_1 = 1.955969, \quad \lambda_2 = 4.044031. \tag{2.7}$$

Obje su strogo pozitivne, pa je $Q \succ 0$ i funkcija cilja je strogo konveksna. Funkcije ograničenja g_1 i g_2 su afine, dakle konveksne, pa je dopustivi skup

$$\mathcal{F} = \{x \in \mathbb{R}^2 \mid Gx - h \leq 0\} \tag{2.8}$$

presjek dvaju zatvorenih poluprostora, tj. zatvoren konveksan skup.

Riječ je, dakle, o konveksnom optimizacijskom problemu. Kako je $Q \succ 0$, funkcija f je koercivna ($f(x) \to \infty$ kada $\|x\| \to \infty$), a skup $\mathcal{F}$ je zatvoren i neprazan, pa minimum postoji; stroga konveksnost daje njegovu jedinstvenost. Za točku $x = [7, 6]^{\mathsf{T}}$ vrijedi $g_1(x) = -3 < 0$ i $g_2(x) = -2 < 0$, pa je Slaterov uvjet zadovoljen. Prema tome su KKT uvjeti nužni i dovoljni za optimalnost i vrijedi jaka dualnost [1, 2].

2.3. (b) KKT uvjeti i njihovo rješavanje

Lagrangeova funkcija problema (2.1)–(2.3) glasi

$$\mathcal{L}(x, \mu) = \tfrac{1}{2}x^{\mathsf{T}}Qx + c^{\mathsf{T}}x + \mu^{\mathsf{T}}(Gx - h), \qquad \mu = [\mu_1, \mu_2]^{\mathsf{T}}. \tag{2.9}$$

KKT uvjeti su:

$$Qx + c + G^{\mathsf{T}}\mu = 0, \qquad (\star) \tag{2.10}$$

$$g_1(x) \leq 0, \quad g_2(x) \leq 0, \qquad (g) \tag{2.11}$$

$$\mu_1 g_1(x) = 0, \quad \mu_2 g_2(x) = 0, \qquad (\star\star) \tag{2.12}$$

$$\mu_1 \geq 0, \quad \mu_2 \geq 0. \qquad (\star\star\star) \tag{2.13}$$

Uvjet stacionarnosti $(\star)$ raspisan po komponentama glasi

$$\begin{bmatrix} 2x_1 - 0.3x_2 + 2 \\ -0.3x_1 + 4x_2 - 3 \end{bmatrix} + \mu_1 \begin{bmatrix} -1 \\ -1 \end{bmatrix} + \mu_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \tag{2.14}$$

Zbog uvjeta komplementarnosti $(\star\star)$ postoje $2^2 = 4$ kombinacije aktivnosti ograničenja, prikazane u tablici 2.1. Oznaka 1 znači da je ograničenje aktivno ($g_i(x) = 0$, $\mu_i \geq 0$), a 0 da nije ($g_i(x) < 0$, $\mu_i = 0$). Za svaku se kombinaciju pretpostavi da vrijedi u optimumu i provjeri mogu li se tada zadovoljiti svi KKT uvjeti.

Tablica 2.1. Kombinacije aktivnosti ograničenja.

Slučaj	g_1	g_2
1	0	0
2	1	0
3	0	1
4	1	1

Slučaj 1 ($\mu_1 = \mu_2 = 0$). Uvjet $(\star)$ svodi se na $Qx + c = 0$, odakle je

$$x^0 = -Q^{-1}c = -\frac{100}{791}\begin{bmatrix} 4 & 0.3 \\ 0.3 & 2 \end{bmatrix}\begin{bmatrix} 2 \\ -3 \end{bmatrix} = \begin{bmatrix} -710/791 \\ 540/791 \end{bmatrix} = \begin{bmatrix} -0.897598 \\ 0.682680 \end{bmatrix}. \tag{2.15}$$

Provjera (g): $g_1(x^0) = 10.214918 > 0$, pa točka nije dopustiva. Slučaj se odbacuje.

Slučaj 2 ($g_1(x) = 0$, $\mu_2 = 0$). Aktivno ograničenje daje $x_1 + x_2 = 10$, a $(\star)$ dvije jednadžbe s nepoznanicama x_1, x_2, μ_1:

$$\begin{bmatrix} 2 & -0.3 & -1 \\ -0.3 & 4 & -1 \\ -1 & -1 & 0 \end{bmatrix}\begin{bmatrix} x_1 \\ x_2 \\ \mu_1 \end{bmatrix} = \begin{bmatrix} -2 \\ 3 \\ -10 \end{bmatrix}. \tag{2.16}$$

Izjednačavanjem izraza za μ_1 iz prve i druge jednadžbe dobiva se $2.3x_1 - 4.3x_2 + 5 = 0$, a uvrštavanjem $x_2 = 10 - x_1$ slijedi $6.6x_1 = 38$, odnosno

$$x_1^* = \frac{190}{33} = 5.757576, \qquad x_2^* = \frac{140}{33} = 4.242424, \tag{2.17}$$

$$\mu_1^* = 2x_1^* - 0.3x_2^* + 2 = \frac{380 - 42 + 66}{33} = \frac{404}{33} = 12.242424. \tag{2.18}$$

Preostali KKT uvjeti su zadovoljeni: $\mu_1^* > 0$ i $\mu_2^* = 0$ zadovoljavaju $(\star\star\star)$, a

$$g_2(x^*) = \frac{190}{33} - \frac{140}{33} - 3 = -\frac{49}{33} = -1.484848 < 0 \tag{2.19}$$

zadovoljava (g) i $(\star\star)$. Ovo je, dakle, rješenje problema:

$$x^* = \begin{bmatrix} 190/33 \\ 140/33 \end{bmatrix}, \qquad \mu^* = \begin{bmatrix} 404/33 \\ 0 \end{bmatrix}, \qquad p^* = f(x^*) = \frac{2000}{33} = 60.606061. \tag{2.20}$$

Slučaj 3 ($\mu_1 = 0$, $g_2(x) = 0$). Iz $x_1 - x_2 = 3$ i $(\star)$ slijedi

$$x_1 = \frac{121}{54} = 2.240741, \quad x_2 = -\frac{41}{54} = -0.759259, \quad \mu_2 = -\frac{3623}{540} = -6.709259. \tag{2.21}$$

Uvjet $(\star\star\star)$ je narušen jer je $\mu_2 < 0$; uz to je i $g_1(x) = 8.518519 > 0$. Slučaj se odbacuje.

Slučaj 4 ($g_1(x) = 0$, $g_2(x) = 0$). Oba aktivna ograničenja daju sjecište pravaca $x_1 + x_2 = 10$ i $x_1 - x_2 = 3$, tj. $x = [6.5,\ 3.5]^\mathsf{T}$. Uvrštavanjem u $(\star)$ dobiva se

$$\begin{bmatrix} -1 & 1 \\ -1 & -1 \end{bmatrix} \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} = - \begin{bmatrix} 13.95 \\ 9.05 \end{bmatrix} \implies \mu_1 = 11.50, \quad \mu_2 = -2.45. \tag{2.22}$$

Uvjet $(\star\star\star)$ je narušen jer je $\mu_2 < 0$. Slučaj se odbacuje.

2.4. (c) Grafički prikaz

U KKT točki x^* gradijenti funkcije cilja i funkcija ograničenja iznose

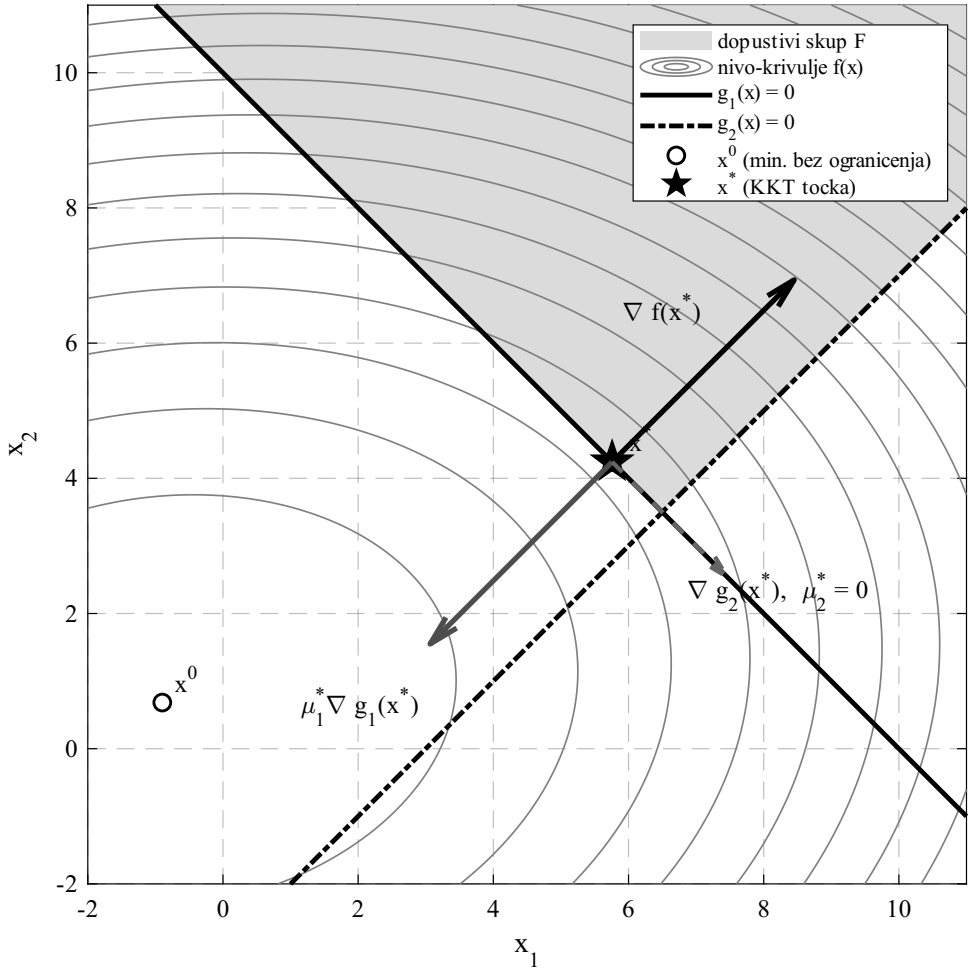
$$\nabla f(x^*) = Qx^* + c = \begin{bmatrix} 12.242424 \\ 12.242424 \end{bmatrix}, \quad \nabla g_1(x^*) = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \quad \nabla g_2(x^*) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \tag{2.23}$$

pa uvjet stacionarnosti $(\star)$ daje

$$\nabla f(x^*) = -\mu_1^* \nabla g_1(x^*) = -\frac{404}{33} \begin{bmatrix} -1 \\ -1 \end{bmatrix}. \tag{2.24}$$

Gradijent funkcije cilja i gradijent aktivnog ograničenja su kolinearni i suprotnog smjera. Ograničenje g_2 je neaktivno ($g_2(x^*) = -1.484848 < 0$), pa je iz $(\star\star)$ $\mu_2^* = 0$ i njegov gradijent ne ulazi u ravnotežu.

Slika 2.1 prikazuje dopustivi skup $\mathcal{F}$ (osjenčano), nivo-krivulje funkcije cilja, minimum bez ograničenja x^0 i KKT točku x^* s ucrtanim gradijentima. Nivo-krivulje su elipse jer je $Q \succ 0$. Duljine vektora na slici su grafički skalirane.



Slika 2.1. Dopustivi skup, nivo-krivulje funkcije cilja i gradijenti u KKT točki x^*.

2.5. (d) Numeričko rješenje u MATLAB-u

Problem se u MATLAB-u rješava funkcijom `quadprog`, koja minimizira $\frac{1}{2}x^\mathsf{T}Qx + c^\mathsf{T}x$ uz $Gx \leq h$, pa se matrice iz (2.5) predaju izravno.

```
Q = [2.0, -0.3; -0.3, 4.0];
c = [2.0; -3.0];
G = [-1.0, -1.0; 1.0, -1.0];
h = [-10.0; 3.0];

opts = optimoptions('quadprog', 'Display', 'none', ...
                    'Algorithm', 'interior-point-convex');
```

```
[x_qp, f_qp, ef_qp, ~, lam_qp] = quadprog(Q, c, G, h, [], [], [], [], [], opts);
```

```
exitflag        = 1
x_opt           = [5.757576; 4.242424]
p*  = fval      = 60.606061
lambda.ineqlin  = [12.242424; 0.000000]
```

Primarne i dualne varijable dobivene rješavačem podudaraju se s analitičkim rezultatom (2.20) do na tolerancije rješavača, što je sažeto u tablici 2.2. Polje `lambda.ineqlin` sadrži upravo Lagrangeove množitelje μ_1^* i μ_2^* iz KKT uvjeta.

Tablica 2.2. Usporedba analitičkog rješenja i rezultata rješavača `quadprog`.

Veličina	Analitički	`quadprog`	Odstupanje
x_1^*	$190/33 = 5.757576$	5.757576	$< 10^{-10}$
x_2^*	$140/33 = 4.242424$	4.242424	$< 10^{-10}$
μ_1^*	$404/33 = 12.242424$	12.242424	$< 10^{-10}$
μ_2^*	0	0	—
p^*	$2000/33 = 60.606061$	60.606061	$< 10^{-10}$

2.6. (e) Lagrangeov dualni problem

Budući da je $Q \succ 0$, matrica Q^{-1} postoji, a Lagrangeova funkcija

$$\mathcal{L}(x, \mu) = \tfrac{1}{2} x^{\mathsf{T}} Q x + (c + G^{\mathsf{T}}\mu)^{\mathsf{T}} x - \mu^{\mathsf{T}} h \tag{2.25}$$

strogo je konveksna po x. Infimum se postiže u točki u kojoj je $\nabla_x \mathcal{L} = 0$:

$$Q\tilde{x} + c + G^{\mathsf{T}}\mu = 0 \implies \tilde{x} = -Q^{-1}(c + G^{\mathsf{T}}\mu). \tag{2.26}$$

Uvrštavanjem $\tilde{x}$ natrag u $\mathcal{L}$ dobiva se dualna funkcija

$$\theta(\mu) = \inf_x \mathcal{L}(x, \mu) = -\tfrac{1}{2}\mu^{\mathsf{T}} G Q^{-1} G^{\mathsf{T}} \mu + \left(-c^{\mathsf{T}} Q^{-1} G^{\mathsf{T}} - h^{\mathsf{T}}\right)\mu - \tfrac{1}{2} c^{\mathsf{T}} Q^{-1} c, \tag{2.27}$$

a dualni problem glasi

$$\max_{\mu \geq 0} \ \theta(\mu). \tag{2.28}$$

Matrica $-GQ^{-1}G^{\mathsf{T}}$ je negativno semidefinitna, pa je θ konkavna kvadratna funkcija, a (2.28) je maksimizacija konkavne funkcije uz konveksna ograničenja, dakle konveksan optimizacijski problem. Riječ je opet o kvadratnom programu, samo u varijabli μ, pa se rješava istom funkcijom `quadprog` primijenjenom na $-\theta(\mu)$ uz donju granicu $\mu \geq 0$.

```
Qi = inv(Q);
Hd = G*Qi*G';  Hd = 0.5*(Hd + Hd');    % Hessian dualnog QP-a
fd = (c'*Qi*G' + h')';
kd = 0.5*(c'*Qi*c);                    % konstantni clan
[mu_d, negd, ef_d] = quadprog(Hd, fd, [], [], [], [], [0;0], [], [], opts);
d_opt = -(negd + kd);
```

```
exitflag        = 1
mu*             = [12.242424; 0.000000]
d*  = theta(mu*)= 60.606061
dualni procjep p* - d* = 2.480e-10
```

Dualne varijable μ^* identične su Lagrangeovim množiteljima dobivenim analitički pod (b) i onima koje je `quadprog` vratio pod (d). Kako je Slaterov uvjet zadovoljen (potpoglavlje (a)), vrijedi jaka dualnost, što potvrđuje i numerički dualni procjep $p^* - d^* = 2.48 \cdot 10^{-10}$. Maksimum konkavne funkcije θ postiže se na rubu $\mu_2 = 0$, što odgovara neaktivnosti drugog primarnog ograničenja.

2.7. (f) Osjetljivost optimalne vrijednosti

Perturbacija desnih strana ograničenja uvodi se vektorom $v = [v_1, v_2]^\mathsf{T}$:

$$p^*(v) = \min \left\{ \tfrac{1}{2} x^\mathsf{T} Q x + c^\mathsf{T} x \;\middle|\; Gx - h \le v \right\}, \tag{2.29}$$

pri čemu v_i odgovara pomaku desne strane b_i i-tog ograničenja. Za konveksan problem sa zadovoljenim Slaterovim uvjetom vrijedi [1, 2]

$$\left. \frac{\partial p^*}{\partial v_i} \right|_{v=0} = -\mu_i^*. \tag{2.30}$$

Uz $\mu^* = [404/33,\ 0]^\mathsf{T}$ slijedi

$$\frac{\partial p^*}{\partial v_1} = -\frac{404}{33} = -12.242424, \qquad \frac{\partial p^*}{\partial v_2} = 0. \tag{2.31}$$

Optimalna vrijednost osjetljiva je samo na perturbaciju prvog ograničenja: opuštanje ograničenja g_1 za $\Delta b_1 > 0$ smanjuje p^* za približno $12.2424\,\Delta b_1$. Perturbacija drugog ograničenja nema utjecaja u prvom redu jer je g_2 u optimumu neaktivno, tj. $\mu_2^* = 0$; to vrijedi sve dok je perturbacija dovoljno mala da se aktivni skup ne promijeni (rezerva do aktivacije iznosi $|g_2(x^*)| = 1.484848$).

Numerička provjera provedena je ponovnim rješavanjem problema uz pomak $\delta = 10^{-4}$:

```
dlt = 1e-4;
[~, f_v1] = quadprog(Q, c, G, h + [dlt; 0], [], [], [], [], [], opts);
[~, f_v2] = quadprog(Q, c, G, h + [0; dlt], [], [], [], [], [], opts);
```

```
dp1 = (f_v1 - f_qp)/dlt;
dp2 = (f_v2 - f_qp)/dlt;
```

```
dp*/dv1 numericki = -12.242364,  -mu1* = -12.242424,  odstupanje = 5.99e-05
dp*/dv2 numericki = 0.000000,  -mu2* = 0.000000,  odstupanje = 0.00e+00
```

Jednostrana numerička derivacija odstupa od $-\mu_1^*$ za $5.99 \cdot 10^{-5}$, što je reda veličine samog koraka δ i u skladu s (2.30).

3. ZADATAK 2: ROBUSNI KVADRATNI PROGRAM

3.1. Skup nesigurnosti i robusna formulacija

Za problem iz Zadatka 1 pretpostavlja se da koeficijenti a_{ij} nisu točno poznati, nego da njihove stvarne vrijednosti leže u intervalu od $\pm 15\%$ oko nominalnih:

$$a_{ij} \in \left[0.85\, a_{ij}^0,\ 1.15\, a_{ij}^0\right], \qquad i,j \in \{1,2\}. \tag{3.1}$$

Uz nominalne vrijednosti $a_{11}^0 = a_{12}^0 = a_{22}^0 = -1$ i $a_{21}^0 = 1$ to daje

$$a_{11}, a_{12}, a_{22} \in [-1.15, -0.85], \qquad a_{21} \in [0.85, 1.15]. \tag{3.2}$$

Retke matrice ograničenja označimo s $a_1 = [a_{11}, a_{12}]^\mathsf{T}$ i $a_2 = [a_{21}, a_{22}]^\mathsf{T}$; njihovi skupovi nesigurnosti su pravokutnici

$$\mathcal{P}_1 = [-1.15, -0.85] \times [-1.15, -0.85], \qquad \mathcal{P}_2 = [0.85, 1.15] \times [-1.15, -0.85]. \tag{3.3}$$

Traži se x koji minimizira istu funkciju cilja i zadovoljava ograničenja za *svaku* realizaciju koeficijenata:

$$\min_x\ \tfrac{1}{2} x^\mathsf{T} Q x + c^\mathsf{T} x \quad \text{uz} \quad a_i^\mathsf{T} x \le h_i \ \text{ za sve } a_i \in \mathcal{P}_i,\ i = 1,2. \tag{3.4}$$

Ograničenja u (3.4) predstavljaju beskonačno mnogo nejednakosti i ekvivalentna su uvjetima

$$\sup_{a_i \in \mathcal{P}_i} a_i^\mathsf{T} x \le h_i, \qquad i = 1,2. \tag{3.5}$$

3.2. Ekvivalentan problem s konačno mnogo nejednakosti

Skupovi $\mathcal{P}_i$ su poliedri, točnije konveksne ljuske svojih vrhova, $\mathcal{P}_i = \operatorname{co}\big(v_i^{(1)}, \ldots, v_i^{(4)}\big)$. Linearna funkcija $a \mapsto a^\mathsf{T} x$ na konveksnoj ljusci poprima maksimum u nekom od generatora:

ako je $a = \sum_k \gamma_k v_i^{(k)}$ uz $\gamma_k \geq 0$, $\sum_k \gamma_k = 1$, tada iz $\left(v_i^{(k)}\right)^{\mathsf{T}} x \leq h_i$ za sve k slijedi

$$a^{\mathsf{T}} x = \sum_k \gamma_k \left(v_i^{(k)}\right)^{\mathsf{T}} x \leq \sum_k \gamma_k h_i = h_i. \tag{3.6}$$

Obrat je očit jer su vrhovi elementi skupa $\mathcal{P}_i$. Zato je robusno ograničenje egzaktno ekvivalentno konačnom skupu nejednakosti u vrhovima [2, 3]:

$$\sup_{a_i \in \mathcal{P}_i} a_i^{\mathsf{T}} x \leq h_i \iff \left(v_i^{(k)}\right)^{\mathsf{T}} x \leq h_i, \quad k = 1, \ldots, 4. \tag{3.7}$$

Svaki pravokutnik ima $2^2 = 4$ vrha, pa se dobiva ukupno 8 linearnih nejednakosti:

$$\begin{aligned} -0.85x_1 - 0.85x_2 &\leq -10, & 0.85x_1 - 0.85x_2 &\leq 3, \\ -0.85x_1 - 1.15x_2 &\leq -10, & 0.85x_1 - 1.15x_2 &\leq 3, \\ -1.15x_1 - 0.85x_2 &\leq -10, & 1.15x_1 - 0.85x_2 &\leq 3, \\ -1.15x_1 - 1.15x_2 &\leq -10, & 1.15x_1 - 1.15x_2 &\leq 3. \end{aligned} \tag{3.8}$$

Robusni problem je time postao obični kvadratni program

$$\min_x \ \tfrac{1}{2} x^{\mathsf{T}} Q x + c^{\mathsf{T}} x \quad \text{uz} \quad G_{\text{rob}} x \leq h_{\text{rob}}, \tag{3.9}$$

gdje je $G_{\text{rob}} \in \mathbb{R}^{8\times 2}$ sastavljena od vrhova, a $h_{\text{rob}} = [-10, -10, -10, -10, 3, 3, 3, 3]^{\mathsf{T}}$.

3.3. Analitičko rješenje i provjera KKT uvjeta

Pretpostavimo da optimum leži u pozitivnom kvadrantu, $x_1 \geq 0$, $x_2 \geq 0$; pretpostavka se provjerava naknadno. Tada je od četiri nejednakosti prvog ograničenja najrestriktivnija ona s najmanjim iznosima koeficijenata, a od četiri nejednakosti drugog ograničenja ona koja maksimizira lijevu stranu:

$$-0.85x_1 - 0.85x_2 \leq -10 \iff x_1 + x_2 \geq \frac{200}{17} = 11.764706, \tag{3.10}$$

$$1.15x_1 - 0.85x_2 \leq 3. \tag{3.11}$$

Ako bi u optimumu bilo aktivno samo (3.10), rješenje bi bilo $x = [6.9073,\ 4.8574]^{\mathsf{T}}$, no tada je

$$1.15(6.9073) - 0.85(4.8574) - 3 = +0.8146 > 0, \tag{3.12}$$

pa točka nije dopustiva za (3.11). Prema tome oba najgora ograničenja moraju biti aktivna. Iz sustava

$$\begin{cases} 0.85x_1 + 0.85x_2 = 10 \\ 1.15x_1 - 0.85x_2 = 3 \end{cases} \tag{3.13}$$

zbrajanjem slijedi $2x_1 = 13$, odnosno

$$x^*_{\text{rob}} = \begin{bmatrix} 13/2 \\ 179/34 \end{bmatrix} = \begin{bmatrix} 6.500000 \\ 5.264706 \end{bmatrix}, \qquad f(x^*_{\text{rob}}) = \frac{978253}{11560} = 84.623962. \tag{3.14}$$

Obje komponente su pozitivne, čime je početna pretpostavka potvrđena.

U toj točki gradijent funkcije cilja iznosi $\nabla f(x^*_{\text{rob}}) = [13.420588,\ 16.108824]^{\mathsf{T}}$, a uvjet stacionarnosti uz dva aktivna vrha daje

$$\nabla f(x^*_{\text{rob}}) + \mu^*_1 \begin{bmatrix} -0.85 \\ -0.85 \end{bmatrix} + \mu^*_7 \begin{bmatrix} 1.15 \\ -0.85 \end{bmatrix} = 0 \implies \mu^*_1 = 17.607439, \quad \mu^*_7 = 1.344118, \tag{3.15}$$

oba strogo pozitivna. Preostalih šest nejednakosti iz (3.8) strogo je zadovoljeno, kako pokazuje tablica 3.1. Time su svi KKT uvjeti zadovoljeni i x^*_{rob} je globalni optimum robusnog problema.

Tablica 3.1. Vrijednosti svih osam vršnih nejednakosti u točki x^*_{rob}.

k	**Vrh** $v^{(k)}$	$\left(v^{(k)}\right)^{\mathsf{T}} x^*_{\text{rob}}$	**Desna strana**	**Status**
1	$(-0.85,\ -0.85)$	-10.0000	-10	aktivno
2	$(-0.85,\ -1.15)$	-11.5794	-10	rezerva 1.5794
3	$(-1.15,\ -0.85)$	-11.9500	-10	rezerva 1.9500
4	$(-1.15,\ -1.15)$	-13.5294	-10	rezerva 3.5294
5	$(0.85,\ -0.85)$	1.0500	3	rezerva 1.9500
6	$(0.85,\ -1.15)$	-0.5294	3	rezerva 3.5294
7	$(1.15,\ -0.85)$	3.0000	3	aktivno
8	$(1.15,\ -1.15)$	1.4206	3	rezerva 1.5794

3.4. Rješenje u MATLAB-u

Matrica G_{rob} gradi se prolaskom kroz sve kombinacije skalirajućih faktora 0.85 i 1.15 za oba koeficijenta svakog retka, a dobiveni kvadratni program rješava se funkcijom `quadprog`.

```
sc = [0.85, 1.15];
G_rob = []; h_rob = [];
for i = 1:2
    for s1 = sc
        for s2 = sc
            G_rob(end+1, :) = [s1*G(i,1), s2*G(i,2)];
            h_rob(end+1, 1) = h(i);
        end
    end
end
[x_rob, ~, ef, ~, lam_rob] = quadprog(Q, c, G_rob, h_rob, ...
```

```
                                        [], [], [], [], [], opts);
```

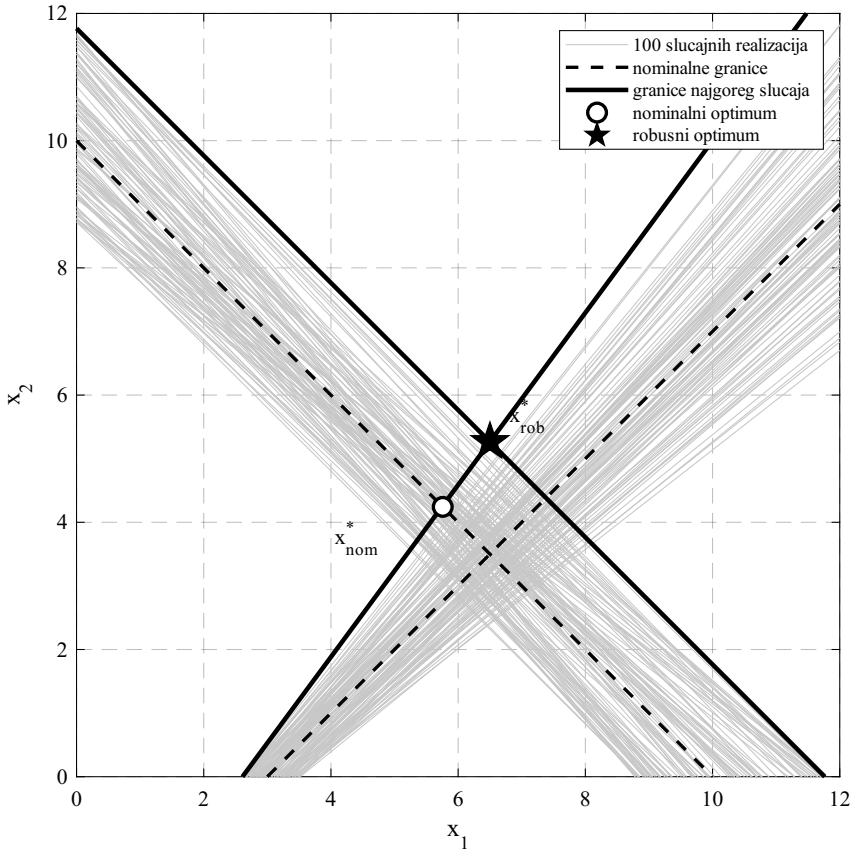
```
exitflag  = 1
x_rob*    = [6.500000; 5.264706]
f(x_rob*) = 84.623962
max(G_rob*x - h_rob) = -2.793e-11
```

3.5. Slučajne realizacije i usporedba s nominalnim rješenjem

Za grafički prikaz generirano je 100 slučajnih realizacija matrice koeficijenata, $a_{ij}^{(k)} = s_{ij}^{(k)} a_{ij}^{0}$ uz $s_{ij}^{(k)} \sim \mathcal{U}(0.85,\ 1.15)$. Generator je inicijaliziran s `rng(42)` radi ponovljivosti.

```
rng(42);
viol_nom = 0; viol_rob = 0;
for k = 1:100
    Gk = G .* (0.85 + 0.30*rand(2,2));
    if any(Gk*x_nom - h > 1e-12), viol_nom = viol_nom + 1; end
    if any(Gk*x_rob - h > 1e-12), viol_rob = viol_rob + 1; end
end
```

```
krsenja za x_nom* : 54 / 100
krsenja za x_rob* : 0 / 100
```



Slika 3.1. Granice ograničenja za 100 slučajnih realizacija koeficijenata (sivo), nominalne granice (crtkano), granice najgoreg slučaja (puna crta) te nominalni i robusni optimum.

Na slici 3.1 vidi se da nominalno rješenje $x^*_{\text{nom}} = (5.757576,\ 4.242424)$ leži točno na nominalnoj granici prvog ograničenja, pa ga svaka realizacija koja tu granicu pomakne prema unutra izbacuje iz dopustivog skupa; u provedenom uzorku to se dogodilo u 54 od 100 realizacija. Robusno rješenje x^*_{rob} nije prekršilo nijednu realizaciju. Dopustivost za *cijeli* skup nesigurnosti ne slijedi iz tog uzorka, nego iz zadovoljenja svih osam vršnih nejednakosti (3.8), kako je pokazano u tablici 3.1; slučajne realizacije samo ilustriraju taj rezultat.

Usporedba s nominalnim rješenjem iz Zadatka 1 dana je u tablici 3.2. Zahtjev za dopustivošću pri svim realizacijama sužava dopustivi skup i pomiče optimum dalje od minimuma bez ograničenja, pa vrijednost funkcije cilja raste za 24.017901, odnosno 39.63%.

Tablica 3.2. Nominalno i robusno rješenje.

Rješenje	x_1^*	x_2^*	$f(x^*)$
Nominalno (Zadatak 1)	5.757576	4.242424	60.606061
Robusno	6.500000	5.264706	84.623962
Razlika	$+0.742424$	$+1.022282$	$+24.017901$ ($+39.63\%$)

4. ZADATAK 3: NIVELACIJA CESTE KAO PROBLEM LINEARNOG PROGRAMIRANJA

4.1. (a) Formulacija problema i klasa kojoj pripada

Trošak izrade ceste proporcionalan je količini materijala koji se otkopava ili nasipa, dakle površini između nivelete ceste $y(x)$ i prirodnog terena $h(x)$. Uz pretpostavku jedinične širine trase ($w = 1$ m) volumen zemljanih radova brojčano je jednak toj površini, izraženoj u m^2. Iskop i nasip ulaze u trošak s jednakim ponderom.

Problem se zapisuje kao

$$\min_{y(\cdot)} \; J[y] = \int_0^L \big|y(x) - h(x)\big| \, \mathrm{d}x \tag{4.1}$$

uz ograničenja

$$|y'(x)| \le b_1, \qquad |y''(x)| \le b_2, \qquad y(0) = a, \quad y(L) = b. \tag{4.2}$$

Zadani su podaci

$$L = 10 \text{ m}, \qquad h(x) = 0.0053x^4 - 0.095x^3 + 0.48x^2 - 0.3x + 1, \tag{4.3}$$

$$a = h(0) = 1 \text{ m}, \qquad b = h(L) = 4 \text{ m}, \tag{4.4}$$

te dva skupa parametara: **slučaj A** s $b_1 = 0.5$, $b_2 = 0.5$ m^{-1} i **slučaj B** s $b_1 = 0.5$, $b_2 = 0.2$ m^{-1}. Veličina b_1 ograničava nagib nivelete (bezdimenzijski, m/m), a b_2 brzinu promjene nagiba, tj. drugu derivaciju nivelete; pri malim nagibima ona je aproksimacija vertikalne zakrivljenosti trase.

Nakon diskretizacije i uklanjanja apsolutne vrijednosti (potpoglavlja 4.2 i 4.3) funkcija cilja i sva ograničenja postaju linearni u optimizacijskim varijablama, pa problem pripada klasi **linearnog programiranja (LP)**. Riječ je o aproksimaciji u normi ℓ_1 s dodatnim linearnim ograničenjima, u obliku obrađenom na vježbama [2]: minimizacija $\|Ax - b\|_1$ svodi se na LP uvođenjem pomoćnog vektora z i ograničenja $-z \le Ax - b \le z$.

4.2. Diskretizacija konačnim razlikama

Interval $[0, L]$ dijeli se na N jednakih podintervala duljine $\Delta x = L/N$, čime nastaje mreža od $N + 1$ čvorova

$$x_i = i\,\Delta x, \quad i = 0, 1, \ldots, N, \qquad x_0 = 0, \; x_N = L. \tag{4.5}$$

Visine terena u čvorovima su $h_i = h(x_i)$, a nepoznanice su visine nivelete $y = [y_0, y_1, \ldots, y_N]^{\mathsf{T}}$.

Prema uputama zadatka nagib se aproksimira prvom podijeljenom razlikom, a brzina

promjene nagiba drugom:

$$\nabla y_i = \frac{y_i - y_{i-1}}{\Delta x}, \quad i = 1, \ldots, N, \qquad \nabla^2 y_i = \frac{\nabla y_i - \nabla y_{i-1}}{\Delta x} = \frac{y_i - 2y_{i-1} + y_{i-2}}{\Delta x^2}, \quad i = 2, \ldots, N. \tag{4.6}$$

U matričnom zapisu je $\nabla y = D_1 y$ i $\nabla^2 y = D_2 y$, gdje su

$$D_1 = \frac{1}{\Delta x} \begin{bmatrix} -1 & 1 & & & \\ & -1 & 1 & & \\ & & \ddots & \ddots & \\ & & & -1 & 1 \end{bmatrix} \in \mathbb{R}^{N \times (N+1)}, \quad D_2 = \frac{1}{\Delta x^2} \begin{bmatrix} 1 & -2 & 1 & & & \\ & 1 & -2 & 1 & & \\ & & \ddots & \ddots & \ddots & \\ & & & 1 & -2 & 1 \end{bmatrix} \in \mathbb{R}^{(N-1) \times (N+1)} \tag{4.7}$$

4.3. Prijelaz na standardni oblik linearnog programa

Integral (4.1) aproksimira se sumom po čvorovima

$$J_{\text{disc}}(y) = \Delta x \sum_{i=0}^{N} |y_i - h_i|. \tag{4.8}$$

Faktor Δx daje kriteriju dimenziju površine [m^2]; kako je riječ o pozitivnoj konstanti, on ne mijenja minimizator, nego samo mjerilo kriterija.

Apsolutna vrijednost uklanja se uvođenjem pomoćnih varijabli $z_i \geq |y_i - h_i|$, što je ekvivalentno paru linearnih nejednakosti

$$y_i - z_i \leq h_i, \qquad -y_i - z_i \leq -h_i, \qquad i = 0, \ldots, N. \tag{4.9}$$

U optimumu je $z_i = |y_i - h_i|$ jer se z_i minimizira. Vektor optimizacijskih varijabli je

$$\vartheta = \begin{bmatrix} y \\ z \end{bmatrix} \in \mathbb{R}^{2(N+1)}, \tag{4.10}$$

a linearni program glasi

$$\min_{\vartheta} \begin{bmatrix} \mathbf{0}^{\mathsf{T}} & \Delta x\, \mathbf{1}^{\mathsf{T}} \end{bmatrix} \vartheta \quad \text{uz} \quad A\vartheta \leq \beta, \quad A_{\text{eq}}\vartheta = \beta_{\text{eq}}, \quad z \geq 0, \tag{4.11}$$

gdje matrica nejednakosti objedinjuje tri skupine ograničenja:

$$A = \begin{bmatrix} I & -I \\ -I & -I \\ D_1 & 0 \\ -D_1 & 0 \\ D_2 & 0 \\ -D_2 & 0 \end{bmatrix}, \qquad \beta = \begin{bmatrix} h \\ -h \\ b_1\mathbf{1}_N \\ b_1\mathbf{1}_N \\ b_2\mathbf{1}_{N-1} \\ b_2\mathbf{1}_{N-1} \end{bmatrix}, \tag{4.12}$$

a rubni uvjeti $y_0 = a$ i $y_N = b$ čine dvije jednakosti. Ukupan broj nejednakosti iznosi

$$2(N+1) + 2N + 2(N-1) = 6N. \tag{4.13}$$

Varijable y_i su slobodne, dok je za z_i donja granica nula.

4.4. (b) Rješenja za četiri zadana slučaja

Linearni program (4.11) rješava se funkcijom `linprog` uz algoritam dualnog simpleksa, u petlji po četiri tražena slučaja.

```
L = 10;
hfun = @(x) 0.0053*x.^4 - 0.095*x.^3 + 0.48*x.^2 - 0.3*x + 1;
opts = optimoptions('linprog', 'Algorithm', 'dual-simplex', 'Display', 'none');

dx = L/N;  x = linspace(0, L, N+1)';  hv = hfun(x);  n = N+1;
f  = [zeros(n,1); dx*ones(n,1)];              % cilj: dx * sum(z)

I  = eye(n);
D1 = (diag(-ones(n,1)) + diag(ones(n-1,1), 1));  D1 = D1(1:N, :)/dx;
D2 = zeros(N-1, n);
for i = 1:N-1
    D2(i, i) = 1;  D2(i, i+1) = -2;  D2(i, i+2) = 1;
end
D2 = D2/dx^2;
Zn = zeros(N, n);  Zc = zeros(N-1, n);

A = [ I, -I;  -I, -I;  D1, Zn;  -D1, Zn;  D2, Zc;  -D2, Zc];
b = [hv;  -hv;  b1*ones(N,1); b1*ones(N,1); b2*ones(N-1,1); b2*ones(N-1,1)];

Aeq = zeros(2, 2*n);  Aeq(1,1) = 1;  Aeq(2,N+1) = 1;
beq = [hv(1); hv(end)];               % rubni uvjeti y0 = a, yN = b
lb  = [-inf(n,1); zeros(n,1)];        % y slobodan, z >= 0

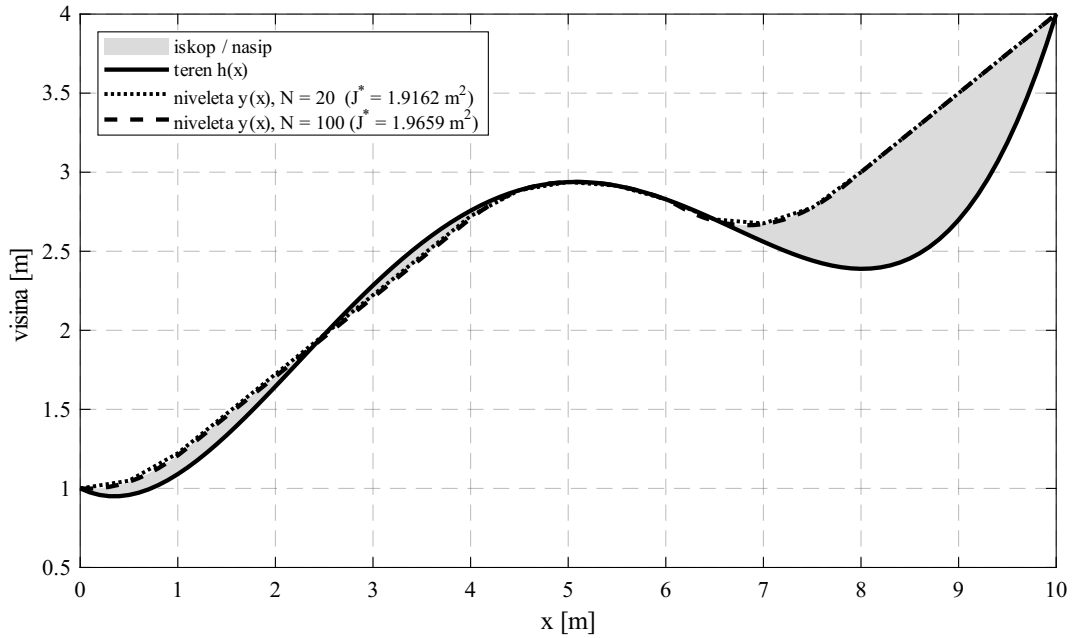
[v, J, ef] = linprog(f, A, b, Aeq, beq, lb, [], opts);
y = v(1:n);
```

```
Slucaj |   N |   dx  |   J* [m^2] | max|Dy| | max|D2y| | var | nejed. | exitflag
  A    |  20 |  0.50 |   1.916180 |  0.5000 |   0.5000 |  42 |    120 | 1
  A    | 100 |  0.10 |   1.965940 |  0.5000 |   0.5000 | 202 |    600 | 1
  B    |  20 |  0.50 |   2.453727 |  0.5000 |   0.2000 |  42 |    120 | 1
  B    | 100 |  0.10 |   2.506047 |  0.5000 |   0.2000 | 202 |    600 | 1
```

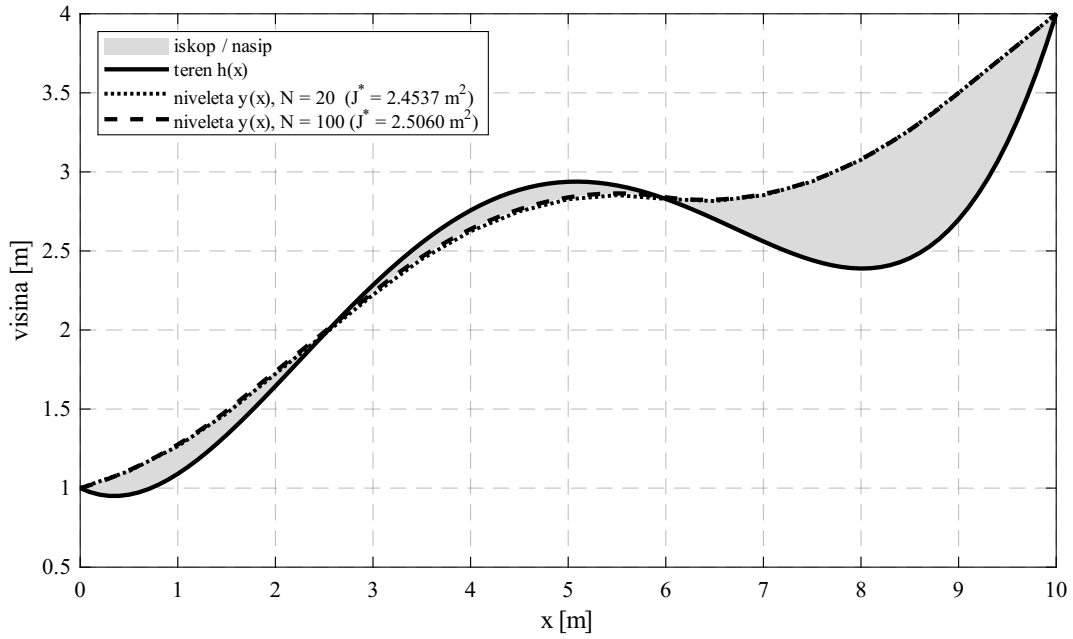
Rezultati su sažeti u tablici 4.1. U sva četiri slučaja oba ograničenja dosežu svoju granicu, tj. i ograničenje nagiba i ograničenje brzine promjene nagiba su aktivna.

Tablica 4.1. Rezultati optimalne nivelacije za četiri zadana slučaja.

Slučaj	N	Δx [m]	J^* [m^2]	$\max_i \lvert\nabla y_i\rvert$	$\max_i \lvert\nabla^2 y_i\rvert$	**varijable / nejed.**
A ($b_2 = 0.5$)	20	0.50	1.916180	0.5000	0.5000	42 / 120
A ($b_2 = 0.5$)	100	0.10	1.965940	0.5000	0.5000	202 / 600
B ($b_2 = 0.2$)	20	0.50	2.453727	0.5000	0.2000	42 / 120
B ($b_2 = 0.2$)	100	0.10	2.506047	0.5000	0.2000	202 / 600



Slika 4.1. Slučaj A ($b_1 = 0.5$, $b_2 = 0.5$ m^{-1}): teren $h(x)$ i optimalna niveleta $y(x)$ za $N = 20$ i $N = 100$.



Slika 4.2. Slučaj B ($b_1 = 0.5$, $b_2 = 0.2$ m^{-1}): teren $h(x)$ i optimalna niveleta $y(x)$ za $N = 20$ i $N = 100$.

4.5. Analiza utjecaja parametara

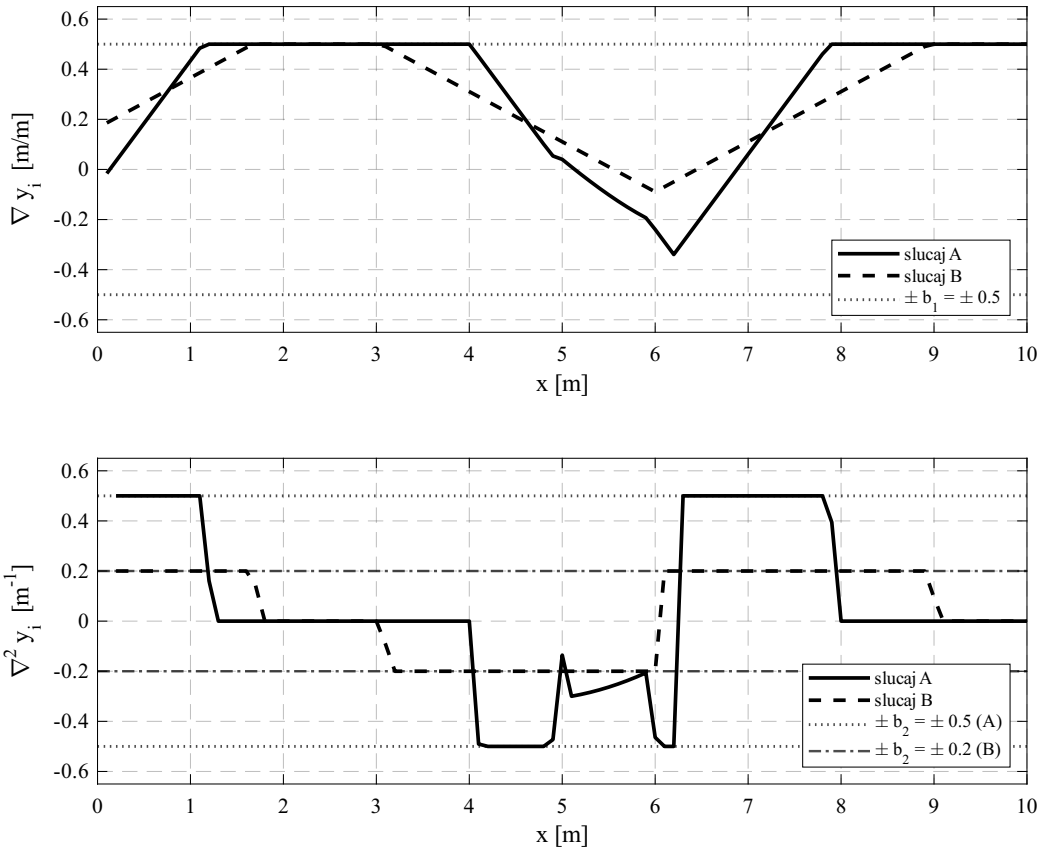
Zašto niveleta odstupa od terena. Nagib terena prelazi dopuštenih $b_1 = 0.5$ na dionicama oko $x \approx 2$–3 m i, znatno jače, na kraju trase, gdje između $x = 9$ i $x = 10$ teren raste za 1.30 m. Kako je $y(10) = 4$ m zadano, a nagib nivelete ograničen na 0.5, mora vrijediti $y(9) \geq 3.5$ i $y(8) \geq 3.0$, dok je $h(9) = 2.698$ m i $h(8) = 2.389$ m. Zbog toga se najveći dio troška javlja kao nasip na dionici $x \in [7, 10]$, što se vidi na slikama 4.1 i 4.2.

Utjecaj gustoće mreže. Prelaskom s $N = 20$ na $N = 100$ kriterij raste sa 1.916180 na 1.965940 m^2 ($+2.60\%$) u slučaju A, odnosno sa 2.453727 na 2.506047 m^2 ($+2.13\%$) u slučaju B. Razlog je u tome što je (4.8) pravokutna kvadratura po čvorovima: na rijetkoj mreži odstupanje $|y - h|$ uzorkovano je u malo točaka, pa dio površine između čvorova izmiče sumi i diskretni kriterij podcjenjuje pravi integral. Pogreška takve kvadrature je reda $O(\Delta x)$, pa se s pet puta gušćom mrežom vrijednost približava kontinuiranom integralu.

Utjecaj ograničenja brzine promjene nagiba. Pooštravanje s $b_2 = 0.5$ m^{-1} (slučaj A) na $b_2 = 0.2$ m^{-1} (slučaj B) prisiljava glađu niveletu: promjena nagiba mora se rasporediti na dulju dionicu, pa niveleta ranije napušta teren i ne može pratiti njegove pregibe. Trošak zbog toga raste sa 1.965940 na 2.506047 m^2 pri $N = 100$, dakle za 27.47%.

Slika 4.3 prikazuje profile ∇y_i i $\nabla^2 y_i$ za oba slučaja pri $N = 100$. Nagib u oba slučaja doseže gornju granicu $+0.5$ na uzlaznim dionicama. Razlika je u drugoj podijeljenoj razlici: u slučaju A ona zasićuje na ± 0.5 m^{-1} na kratkim odsječcima oko prijelaza, dok u slučaju B leži na granici ± 0.2 m^{-1} duž znatno duljih dionica, što je izravan uzrok većeg volumena zemljanih

radova.



Slika 4.3. Provjera ograničenja za $N = 100$: profil nagiba ∇y_i (gore) i brzine promjene nagiba $\nabla^2 y_i$ (dolje) za slučajeve A i B.

5. ZADATAK 4: ROBUSNA STABILIZACIJA SKLOPNOG SUSTAVA

5.1. Model sustava

Promatra se vremenski promjenjiv sustav

$$\dot{x}(t) = A(t)x(t) + Bu(t), \qquad x(t) \in \mathbb{R}^2, \quad u(t) \in \mathbb{R}, \tag{5.1}$$

u kojem se matrica dinamike skokovito mijenja na cjelobrojnim sekundama:

$$A(t) = \begin{cases} A_{\text{parno}}, & \lfloor t \rfloor \text{ paran}, \quad t \in [0,1) \cup [2,3) \cup \dots \\ A_{\text{neparno}}, & \lfloor t \rfloor \text{ neparan}, \quad t \in [1,2) \cup [3,4) \cup \dots \end{cases} \tag{5.2}$$

gdje su

$$A_{\text{parno}} = \begin{bmatrix} -1 & -\frac{\pi}{6} \\ \frac{3\pi}{2} & -1 \end{bmatrix}, \qquad A_{\text{neparno}} = \begin{bmatrix} -1 & -\frac{3\pi}{2} \\ \frac{\pi}{6} & -1 \end{bmatrix}, \qquad B = \begin{bmatrix} 1 \\ 0 \end{bmatrix}. \tag{5.3}$$

Između dva trenutka prespajanja sustav je linearan i vremenski invarijantan, pa ima dva dinamička moda.

5.2. (a) Jesu li matrice modova Hurwitzove?

Karakteristični polinom parnog moda glasi

$$\det(\lambda I - A_{\text{parno}}) = \det \begin{bmatrix} \lambda+1 & \frac{\pi}{6} \\ -\frac{3\pi}{2} & \lambda+1 \end{bmatrix} = (\lambda+1)^2 + \frac{\pi}{6}\cdot\frac{3\pi}{2} = (\lambda+1)^2 + \frac{\pi^2}{4} = 0, \quad (5.4)$$

odakle je

$$\lambda_{1,2}(A_{\text{parno}}) = -1 \pm j\frac{\pi}{2} = -1 \pm 1.570796\, j. \quad (5.5)$$

Za neparni mod umnožak izvandijagonalnih elemenata jednak je istoj vrijednosti, $\frac{3\pi}{2}\cdot\frac{\pi}{6} = \frac{\pi^2}{4}$, pa je karakteristični polinom identičan, odnosno

$$\lambda_{1,2}(A_{\text{neparno}}) = -1 \pm j\frac{\pi}{2}. \quad (5.6)$$

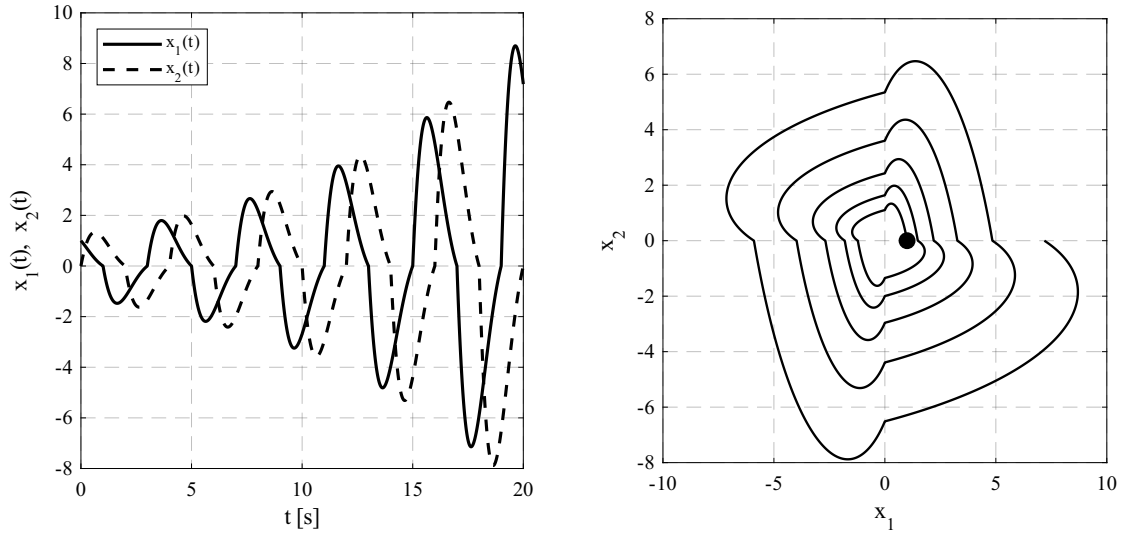
Realni dio svih svojstvenih vrijednosti je $-1 < 0$, pa su **obje matrice Hurwitzove** i svaki mod je zasebno asimptotski stabilan.

5.3. (b) Simulacija sklopnog sustava

Autonomni sustav ($u \equiv 0$) simulira se po segmentima duljine 1 s, jer je unutar svakog segmenta matrica dinamike konstantna. Na svakom segmentu koristi se `ode45`, a završno stanje segmenta postaje početno stanje sljedećeg.

```
A_par = [-1, -pi/6;   3*pi/2, -1];
A_nep = [-1, -3*pi/2; pi/6,   -1];
x0 = [1; 0];  T = 20;

tt = [];  xx = [];  xc = x0;
for kseg = 0:T-1
    if mod(kseg, 2) == 0, Aa = A_par; else, Aa = A_nep; end
    o = odeset('RelTol', 1e-9, 'AbsTol', 1e-11);
    [ts, xs] = ode45(@(t, x) Aa*x, [kseg, kseg+1], xc, o);
    tt = [tt; ts];  xx = [xx; xs];  xc = xs(end,:)';
end
```



Slika 5.1. Otvoreni krug uz $x(0) = [1, 0]^\mathsf{T}$: vremenski odziv varijabli stanja (lijevo) i trajektorija u prostoru stanja (desno).

Slika 5.1 pokazuje da amplitude rastu, a trajektorija u prostoru stanja opisuje spiralu koja se širi; na kraju simulacije je $\|x(20)\| = 7.19$. **Sklopni sustav nije stabilan**, iako su oba moda pojedinačno stabilna.

Taj se zaključak može i dokazati. Matrice prijelaza stanja preko jednog segmenta jesu $\Phi_{\text{parno}} = e^{A_{\text{parno}}}$ i $\Phi_{\text{neparno}} = e^{A_{\text{neparno}}}$. Kako je $A_{\text{parno}} = -I + \frac{\pi}{2}M$ uz $M = \left[\begin{smallmatrix} 0 & -1/3 \\ 3 & 0 \end{smallmatrix}\right]$ i $M^2 = -I$, vrijedi $e^{\frac{\pi}{2}M} = \cos\frac{\pi}{2}I + \sin\frac{\pi}{2}M = M$, pa je

$$\Phi_{\text{parno}} = e^{-1}\begin{bmatrix} 0 & -\frac{1}{3} \\ 3 & 0 \end{bmatrix} = \begin{bmatrix} 0 & -0.122626 \\ 1.103638 & 0 \end{bmatrix}, \tag{5.7}$$

$$\Phi_{\text{neparno}} = e^{-1}\begin{bmatrix} 0 & -3 \\ \frac{1}{3} & 0 \end{bmatrix} = \begin{bmatrix} 0 & -1.103638 \\ 0.122626 & 0 \end{bmatrix}. \tag{5.8}$$

Matrica prijelaza preko jednog punog perioda prespajanja ($T = 2$ s) jest

$$\Phi_{\text{cikl}} = \Phi_{\text{neparno}}\Phi_{\text{parno}} = e^{-2}\begin{bmatrix} -9 & 0 \\ 0 & -\frac{1}{9} \end{bmatrix} = \begin{bmatrix} -1.218018 & 0 \\ 0 & -0.015037 \end{bmatrix}, \tag{5.9}$$

uz $\det\Phi_{\text{cikl}} = e^{-4} = 0.018316$, u skladu s $\det e^A = e^{\text{tr}\,A}$. Budući da je matrica dijagonalna, njezine svojstvene vrijednosti su dijagonalni elementi, pa je spektralni radijus

$$\rho(\Phi_{\text{cikl}}) = 9e^{-2} = 1.218018 > 1. \tag{5.10}$$

Stanje u trenucima $t_k = 2k$ zadovoljava $x(2(k+1)) = \Phi_{\text{cikl}}\, x(2k)$, pa uz $\rho > 1$ norma stanja raste po geometrijskoj progresiji. Simulacija na slici 5.1 numerička je ilustracija tog zaključka.

5.4. (c) Sinteza regulatora pomoću linearnih matričnih nejednakosti

Traži se statički regulator $u(t) = Kx(t)$, $K \in \mathbb{R}^{1\times 2}$, takav da je zatvoreni krug

$$\dot{x}(t) = \big(A(t) + BK\big)x(t) \tag{5.11}$$

eksponencijalno stabilan. Označimo $\mathcal{A} = \{A_{\text{parno}} + BK,\ A_{\text{neparno}} + BK\}$. Prema pojmu kvadratne stabilnosti [2, 4], ako postoji simetrična matrica P takva da vrijedi

$$P \succ 0, \qquad \bar{A}^{\mathsf{T}}P + P\bar{A} \prec 0 \quad \text{za sve } \bar{A} \in \mathcal{A}, \tag{5.12}$$

tada je funkcija $V(x) = x^{\mathsf{T}}Px$ zajednička kvadratna Ljapunovljeva funkcija za oba moda, a vremenski promjenjiv sustav $\dot{x} = \bar{A}(t)x$ je eksponencijalno stabilan za *svaki* po dijelovima kontinuiran izbor $\bar{A}(t) \in \mathcal{A}$ — dakle i za zadani zakon prespajanja (5.2). Upravo je to svojstvo potrebno: kao što pokazuje potpoglavlje (b), Hurwitzovost pojedinih modova sama po sebi ne jamči ništa.

Uvjet (5.12) nije LMI jer sadrži umnožak nepoznanica P i K:

$$A_i^{\mathsf{T}}P + K^{\mathsf{T}}B^{\mathsf{T}}P + PA_i + PBK \prec 0. \tag{5.13}$$

Množenjem s lijeva i s desna matricom P^{-1} (transformacija kongruencije, koja čuva predznak) i supstitucijom

$$\mathcal{Q} = P^{-1}, \qquad Y = KP^{-1} \tag{5.14}$$

dobiva se sustav linearnih matričnih nejednakosti u varijablama $(\mathcal{Q}, Y)$:

$$\mathcal{Q} \succ 0, \qquad A_i\mathcal{Q} + \mathcal{Q}A_i^{\mathsf{T}} + BY + Y^{\mathsf{T}}B^{\mathsf{T}} \prec 0, \qquad i \in \{\text{parno}, \text{neparno}\}. \tag{5.15}$$

Iz rješenja se rekonstruiraju $P = \mathcal{Q}^{-1}$ i $K = YP$.

Sustav (5.15) je homogen: ako je $(\mathcal{Q}, Y)$ dopustiv, dopustiv je i $(t\mathcal{Q}, tY)$ za $t \geq 1$, uz isti K. Stroge nejednakosti se stoga numerički realiziraju usklađenim parom normalizacija $\mathcal{Q} \succeq I$ i $A_i\mathcal{Q} + \mathcal{Q}A_i^{\mathsf{T}} + BY + Y^{\mathsf{T}}B^{\mathsf{T}} \preceq -I$, a među dopustivim parovima bira se onaj s najmanjom normom $\|Y\|$, čime se dobiva regulator najmanjeg pojačanja. Problem se rješava u YALMIP-u rješavačem SDPT3.

```
Qv = sdpvar(2, 2, 'symmetric');
Yv = sdpvar(1, 2, 'full');
F  = [Qv >= eye(2), ...
      A_par*Qv + Qv*A_par' + B*Yv + Yv'*B' <= -eye(2), ...
      A_nep*Qv + Qv*A_nep' + B*Yv + Yv'*B' <= -eye(2)];
sol = optimize(F, norm(Yv, 2), sdpsettings('solver', 'sdpt3', 'verbose', 0));

Qs = value(Qv);  Ys = value(Yv);
```

```
P  = inv(Qs);    K  = Ys*P;
```

```
status : Successfully solved (SDPT3)
Q = [ 1.354304 -0.385757; -0.385757  1.420003]
Y = [-4.597618  1.172472]
P = [ 0.800314  0.217413;  0.217413  0.763286],  eig(P) = 0.563600, 1.000000
K = [-3.424629 -0.104650]
```

Dobiveni su, dakle,

$$P = \begin{bmatrix} 0.800314 & 0.217413 \\ 0.217413 & 0.763286 \end{bmatrix} \succ 0, \qquad K = \begin{bmatrix} -3.424629 & -0.104650 \end{bmatrix}. \tag{5.16}$$

Sustav (5.15) je problem dopustivosti i nema jedinstveno rješenje; drugi rješavač ili druga normalizacija daju drugi K koji također stabilizira zatvoreni krug. U ovom su radu svi rezultati i sve slike dobiveni s pojačanjem (5.16).

5.4.1. Provjera dobivenog rješenja

Matrice zatvorenog kruga iznose

$$A_{\text{parno}}+BK = \begin{bmatrix} -4.424629 & -0.628249 \\ 4.712389 & -1.000000 \end{bmatrix}, \qquad A_{\text{neparno}}+BK = \begin{bmatrix} -4.424629 & -4.817039 \\ 0.523599 & -1.000000 \end{bmatrix}, \tag{5.17}$$

sa svojstvenim vrijednostima

$$\lambda(A_{\text{parno}}+BK) = -2.712315 \pm 0.168908\, j, \qquad \lambda(A_{\text{neparno}}+BK) = \{-3.352491,\ -2.072138\}, \tag{5.18}$$

dakle oba su moda zatvorenog kruga Hurwitzova. To je nužan, ali ne i dovoljan uvjet; dokaz stabilnosti sklopnog sustava daje zajednička Ljapunovljeva funkcija. Njezina provjera:

$$\lambda_{\max}\big((A_{\text{parno}} + BK)^{\mathsf{T}}P + P(A_{\text{parno}} + BK)\big) = -0.910478 < 0, \tag{5.19}$$

$$\lambda_{\max}\big((A_{\text{neparno}} + BK)^{\mathsf{T}}P + P(A_{\text{neparno}} + BK)\big) = -0.329090 < 0, \tag{5.20}$$

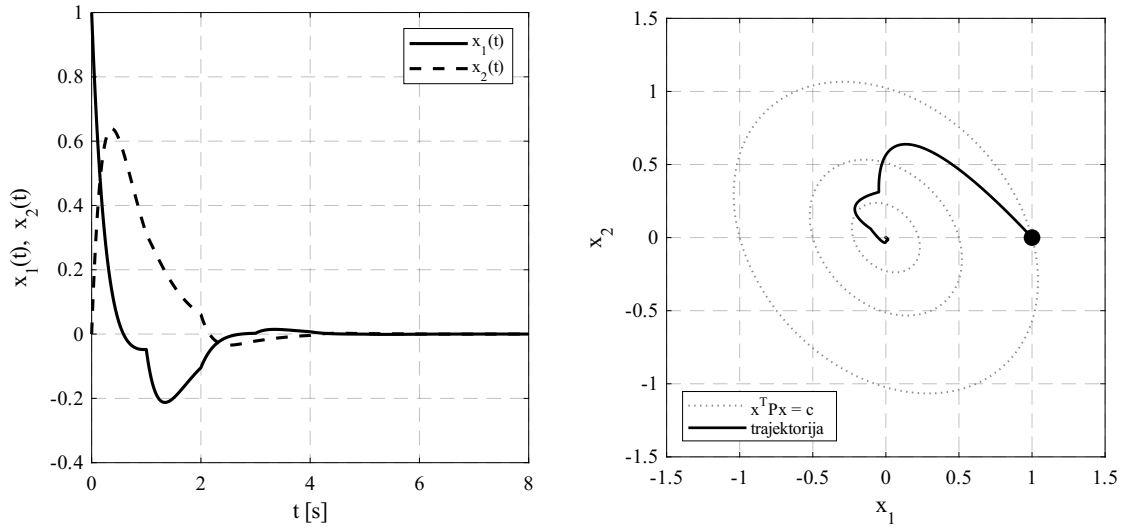
pa (5.12) vrijedi i $V(x) = x^{\mathsf{T}}Px$ strogo pada duž trajektorija oba moda. Iz $\dot{V} \le -2\alpha V$ slijedi eksponencijalna ocjena

$$V(x(t)) \le V(x(0))\, e^{-2\alpha t}, \qquad \alpha = 0.288374\ \text{s}^{-1}, \tag{5.21}$$

odnosno $\|x(t)\| \le 1.3320\, e^{-0.2884t}\|x(0)\|$. Spektralni radijus monodromijske matrice zatvorenog kruga iznosi $\rho(\Phi^{\text{zk}}_{\text{cikl}}) = 0.069720 \ll 1$, što je znatno brža kontrakcija od zajamčene ocjene jer se ona odnosi na proizvoljno prespajanje, a ne samo na zadano periodičko.

5.4.2. Simulacija zatvorenog kruga

Zatvoreni krug simulira se istim postupkom kao u potpoglavlju (b), uz zamjenu $A_i \to A_i + BK$.



Slika 5.2. Zatvoreni krug uz $x(0) = [1, 0]^\mathsf{T}$: vremenski odziv (lijevo) i trajektorija u prostoru stanja s nivo-elipsama $x^\mathsf{T} P x = c$ (desno).

Slika 5.2 pokazuje da stanja konvergiraju prema ishodištu: već je $\|x(5)\| = 1.52 \cdot 10^{-3}$, a $\|x(20)\| = 4.72 \cdot 10^{-12}$. Zbog kompleksnog para polova parnog moda odziv je prigušeno oscilatoran. Trajektorija u prostoru stanja siječe nivo-elipse funkcije $V(x) = x^\mathsf{T} P x$ prema unutrašnjosti, u skladu s $\dot{V} < 0$.

6. ZAKLJUČAK

Zadatak 1. Problem je konveksan: Hesseova matrica ima svojstvene vrijednosti 1.955969 i 4.044031, dakle $Q \succ 0$, a ograničenja su afina. Od četiri kombinacije aktivnosti ograničenja KKT uvjete zadovoljava samo ona s aktivnim g_1, što daje

$$x^* = \left(\tfrac{190}{33},\ \tfrac{140}{33}\right) = (5.757576,\ 4.242424), \qquad \mu^* = \left(\tfrac{404}{33},\ 0\right), \qquad p^* = \tfrac{2000}{33} = 60.606061.$$

Rješavač `quadprog` vraća iste primarne i dualne varijable. Dualni problem je opet kvadratni program u μ; njegovo rješenje μ^* podudara se s množiteljima iz KKT uvjeta, a dualni procjep iznosi $2.48 \cdot 10^{-10}$, pa jaka dualnost vrijedi, kako i predviđa zadovoljen Slaterov uvjet. Optimalna vrijednost osjetljiva je samo na perturbaciju prvog ograničenja, $\partial p^*/\partial v_1 = -12.242424$, dok je $\partial p^*/\partial v_2 = 0$ jer je g_2 neaktivno.

Zadatak 2. Uz nesigurnost koeficijenata od $\pm 15\%$ svako se robusno ograničenje svodi na četiri nejednakosti u vrhovima pravokutnog skupa nesigurnosti, pa robusni problem postaje kvadratni

program s osam linearnih nejednakosti. Njegovo rješenje je

$$x^*_{\text{rob}} = \left(\tfrac{13}{2},\ \tfrac{179}{34}\right) = (6.500000,\ 5.264706), \qquad f(x^*_{\text{rob}}) = 84.623962,$$

uz dva aktivna vrha i strogo pozitivne pripadajuće množitelje $\mu = (17.607439,\ 1.344118)$. U uzorku od 100 slučajnih realizacija (`rng(42)`) nominalno rješenje krši ograničenja u 54 slučaja, a robusno ni u jednom; dopustivost na cijelom skupu nesigurnosti jamči zadovoljenje svih osam vršnih nejednakosti. Za tu se dopustivost plaća porast funkcije cilja od 24.017901, odnosno 39.63%.

Zadatak 3. Nakon diskretizacije konačnim razlikama i uvođenja pomoćnih varijabli $z_i \geq |y_i - h_i|$ problem pripada klasi **linearnog programiranja**, s $2(N+1)$ varijabli i $6N$ nejednakosti. Rezultati za četiri zadana slučaja jesu:

$$\begin{aligned} &\text{slučaj A}, N = 20: \quad J^* = 1.916180\ \text{m}^2 \quad \text{slučaj B}, N = 20: \ J^* = 2.453727\ \text{m}^2 \\ &\text{slučaj A}, N = 100: \quad J^* = 1.965940\ \text{m}^2 \quad \text{slučaj B}, N = 100: \ J^* = 2.506047\ \text{m}^2 \end{aligned}$$

Gušća mreža povećava vrijednost kriterija za oko 2% jer pravokutna kvadratura na rijetkoj mreži podcjenjuje integral. Pooštravanje ograničenja brzine promjene nagiba s $b_2 = 0.5$ na $b_2 = 0.2\ \text{m}^{-1}$ zahtijeva glađu niveletu i povećava volumen zemljanih radova za 27.47%; u oba slučaja aktivna su i ograničenje nagiba i ograničenje brzine promjene nagiba.

Zadatak 4. Obje matrice modova su Hurwitzove, sa svojstvenim vrijednostima $-1 \pm j\pi/2$. Unatoč tome **sklopni sustav nije stabilan**: matrica prijelaza preko jednog perioda prespajanja iznosi $\Phi_{\text{cikl}} = e^{-2}\,\text{diag}(-9,\ -1/9)$, pa je $\rho(\Phi_{\text{cikl}}) = 9e^{-2} = 1.218018 > 1$ i norma stanja raste, što potvrđuje i simulacija. Zahtjev da postoji zajednička kvadratna Ljapunovljeva funkcija preveden je kongruentnom transformacijom i supstitucijom $\mathcal{Q} = P^{-1}$, $Y = KP^{-1}$ u sustav linearnih matričnih nejednakosti. Njegovim rješavanjem dobiven je regulator

$$K = \begin{bmatrix} -3.424629 & -0.104650 \end{bmatrix},$$

uz $P \succ 0$ za koji je $\lambda_{\max}\big((A_i + BK)^{\mathsf{T}}P + P(A_i + BK)\big)$ jednak -0.910478 odnosno -0.329090 za dva moda. Zatvoreni krug je time eksponencijalno stabilan uz zajamčenu stopu $\alpha = 0.288374\ \text{s}^{-1}$, a simulacija pokazuje pad norme stanja na $1.52 \cdot 10^{-3}$ unutar 5 sekundi.

LITERATURA

[1] Stephen Boyd and Lieven Vandenberghe. *Convex Optimization*. Cambridge University Press, Cambridge, UK, 2004.

[2] Andrej Jokić. Optimizacijske metode u razvoju i upravljanju sustava — nastavni materijali i predavanja. Sveučilište u Zagrebu, Fakultet strojarstva i brodogradnje, 2024. Predavanja 01–08 i auditorne vježbe 1–5.

[3] Aharon Ben-Tal, Laurent El Ghaoui, and Arkadi Nemirovski. *Robust Optimization*. Princeton University Press, Princeton, NJ, 2009.

[4] Stephen Boyd, Laurent El Ghaoui, Eric Feron, and Venkataramanan Balakrishnan. *Linear Matrix Inequalities in System and Control Theory*. SIAM, Philadelphia, PA, 1994.